Algoritmi e strutture dati

Giacomo Fantoni

Telegram: @GiacomoFantoni

 ${\bf Github:\ https://github.com/giacThePhantom/AlgoritmiStruttureDati}$

18 febbraio 2020

Indice

1	Intr	Introduzione					
	1.1	Descri	zione di un algoritmo	7			
		1.1.1	Pseudo-codice	7			
	1.2	Valuta	azione degli algoritmi	8			
		1.2.1	Efficienza	8			
		1.2.2	Correttezza	8			
2	Ana	Analisi di algoritmi					
	2.1	Model	lli di calcolo	11			
		2.1.1	Macchina di Turing	12			
		2.1.2	Random Access Machine (RAM)	12			
	2.2	Funzio	oni di costo, analisi asintotica	12			
		2.2.1	Notazione \mathbf{O}	12			
		2.2.2	Notazione Ω	13			
		2.2.3	Notazione Θ	13			
		2.2.4	Proprietà della notazione asintotica	13			
		2.2.5	Notazioni \mathbf{o} , ω	16			
		2.2.6	Classificazione delle funzioni	17			
	2.3	Ricorr	renze	17			
		2.3.1	Analisi per livelli	17			
		2.3.2	Metodo della sostituzione	17			
		2.3.3	Metodo delle ricorrenze comuni	17			
	2.4	one tra complessità di un problema e di un algoritmo	18				
		2.4.1	Complessità in tempo di un algoritmo	19			
		2.4.2	Complessità in tempo di un problema computazionale	19			
	2.5	Valuta	are algoritmi in base alla tipologia di input	19			
		2.5.1	Tipologie di analisi	19			
		2.5.2	Algoritmi di ordinamento	19			
	2.6	Analis	si ammortizzata	22			
		2.6.1	Metodi per l'analisi ammortizzata	22			

INDICE

3	Stri	itture dati	25			
	3.1 Sequenza					
	3.2	Insiemi	26			
	3.3	Dizionari	28			
	3.4	Alberi e grafi	28			
		3.4.1 Alberi ordinati	28			
		3.4.2 Grafi	28			
		3.4.3 Operazioni	28			
	3.5	Lista	29			
	3.6	Pila	30			
	3.7	Coda	30			
	5.1	Coda	30			
4	Alb	eri	33			
	4.1	Alberi radicati	33			
		4.1.1 Definizioni	33			
		4.1.2 Terminologia	33			
	4.2	Visite di alberi	34			
		4.2.1 Visita in profondità	34			
		4.2.2 Visita in ampiezza	34			
	4.3	Albero binario	34			
		4.3.1 Specifica	35			
		4.3.2 Memorizzazione e implementazione	35			
		4.3.3 Visita in profondità	36			
	4.4	Alberi generici	36			
		4.4.1 Specifica	36			
		4.4.2 Memorizzazione	37			
_	A 11_	! 1!!	20			
5		eri di ricerca	39			
	5.1	Specifica	39			
		5.1.1 Ricerca	40			
		5.1.2 Minimo e massimo	40			
		5.1.3 Successore e predecessore	41			
		5.1.4 Inserimento	41			
		5.1.5 Cancellazione	42			
	5.2	Costo computazionale	43			
	5.3	Alberi di ricerca bilanciati	44			
		5.3.1 Alberi red-black	45			
6	Has	hing	51			
_		6.0.1 Definizioni	51			
	6.1	Funzioni hash	52			
	J.1	6.1.1 Come realizzare una funzione hash	52			
	6.2	Le collisioni	53			
	0.2	6.2.1 Liste o vettori di trabocco (Concatenamento o chaining).	53			
		6.2.2 Indirizzamento aperto	54			
	6.3	Complessità	57			
	0.0	Complessiva	91			

INDICE

_						
7			dizionari	59		
	7.1	Insiem		60		
		7.1.1	Insiemi realizzati con vettori booleani	60		
		7.1.2	Insiemi realizzati con liste	61		
		7.1.3	Strutture dati complesse	62		
	7.2	Bloom	filters	62		
		7.2.1	Specifica	62		
		7.2.2	Applicazioni	62		
		7.2.3	Implementazione	63		
		7.2.4	Caratterizzazione matematica	63		
8	Gra	fi		65		
		8.0.1	Definizioni	65		
		8.0.2	Specifica	66		
	8.1		rizzare grafi	67		
	0.1	8.1.1	Matrice di adiacenza	67		
		8.1.2	Liste di adiacenza	67		
		8.1.3	Iterazioni su nodi e archi	68		
	8.2	00	dei grafi	68		
	0.2	8.2.1	Visita in ampiezza o breadth-first search	69		
		8.2.2	Visita in profondità o depth-first search	70		
•	C 1		1.4.	79		
9		· · · · · · · · · · · · · · · · · · ·				
	9.1		con priorità	79		
		9.1.1	Specifica	79		
		9.1.2	Implementazioni	80		
		9.1.3	Heap	80		
		9.1.4	Implementazione di code con priorità	83		
	9.2		ii disgiunti - Merge-find set	85		
		9.2.1	Specifica	86		
		9.2.2	Componenti connesse dinamiche	86		
10	Prog	gramm	nazione dinamica	87		
	10.1	Appro	ccio generale	87		
			Evitare di risolvere i problemi più di una volta	87		
			Ricostruire la soluzione	88		
	10.9		ization	00		

Capitolo 1

Introduzione

Problema computazionale

Dati un dominio di input e uno di output, un problema computazionale è rappresentato dalla funzione matematica che associa un elemento del dominio di output ad ogni elemento del dominio di input.

Algoritmo

Dato un problema computazionale, un algoritmo è un procedimento effettivo espresso tramite una funzione di passi elementari ben specificati in un sistema formale di calcolo che risolve il problema in tempo finito.

1.1 Descrizione di un algoritmo

Per descrivere un algoritmo si rende necessario utilizzare un linguaggio formale ben definito detto pseudo-codice, indipendente dall'implementazione effettiva ma con dettaglio sufficiente a descrivere i passaggi necessari alla descrizione dell'algoritmo.

1.1.1 Pseudo-codice

- \bullet a=b.
- $a \leftrightarrow b \equiv tmp = a; a = b; b = tmp$.
- $T[A = \mathbf{new} \ T[1 \dots n].$
- $T[][]A = \mathbf{new} \ T[1 \dots n][1 \dots m].$
- Tipi in grassetto.
- and, or, not.

1.2. VALUTAZIONE DEGLI ALGORITMI

- $\bullet ==, \neq, \geq, \leq.$
- \bullet +, -, ·, /, |x|, [x], \log, x^2, \cdots .
- $iif(condizione, v_1, v_2)$.
- if condizione then istruzione.
- if conditione then $istruzione_1$ else then $istruzione_2$.
- while condizione do istruzione.
- foreach $elemento \in insieme$ do istruzione.
- return
- % commento.

1.2 Valutazione degli algoritmi

1.2.1 Efficienza

Si definisce complessità di un algoritmo l'analisi delle risorse necessarie per la sua risoluzione, in funzione di tipologia e dimensione di input. Le risorse si distinguono in tempo, memoria e banda (per gli algoritmi distribuiti).

Tempo

Il numero di secondi necessari alla risoluzione dell'algoritmo dipende da troppi fattori, si utilizzano pertanto tecniche di analisi che prendono in considerazione il numero di operazioni rilevanti, quelle che caratterizzano lo scopo dell'algoritmo.

1.2.2 Correttezza

Per valutare la correttezza di algoritmi si devono considerare le invarianti:

- Invariante: una condizione che deve rimanere vera sempre in un certo punto del programma.
- Invariante di ciclo: una condizione che deve rimanere vera all'inizio dell'iterazione di un ciclo.
- Invariante di classe: una condizione sempre vera al termine dell'esecuzione di un metodo di una classe.

Invariante di ciclo e algoritmi iterativi

L'invariante di ciclo permette di dimostrare la correttezza degli algoritmi iterativi attraverso il principio di induzione:

- $\bullet\,$ Inizializzazione (caso base): l'invariante è vera prima della prima iterazione.
- Conservazione (passo induttivo): se la condizione è vera prima di un'interazione allora rimane vera al suo termine.
- Conclusione: quando il ciclo termina l'invariante deve rappresentare la correttezza dell'algoritmo.

Capitolo 2

Analisi di algoritmi

Per definire la complessità di un algoritmo occorre definire una funzione che ha come dominio la dimensione dell'input e come insieme immagine il tempo.

Dimensione dell'input

La dimensione dell'input può essere definita secondo due criteri:

- Criterio di costo logaritmico: la taglia dell'input è il numero di bit necessari a rappresentarlo.
- Criterio di costo uniforme: la taglia dell'input è il numero di elementi di cui è costituito.

In molti casi si può assumere che gli elementi siano costituiti da un numero costante di bit, e in tal caso le due misure coincidono a meno di una costante moltiplicativa.

Definizione di tempo

Si definisce il tempo come il numero di istruzioni elementari necessarie al completamento dell'algoritmo. Si definisce elementare una funzione che può essere svolta in tempo costante dal processore.

2.1 Modelli di calcolo

Un modello di calcolo è una rappresentazione astratta del calcolatore. L'astrazione permette di nascondere dei dettagli, il suo realismo permette di riflettere con un certo grado di precisione una situazione reale e la potenza matematica di trarre conclusioni formali sul costo.

2.1.1 Macchina di Turing

Una macchina di Turing è una macchina ideale che manipola i dati contenuti su un nastro di lunghezza infinita secondo un insieme prefissato di regole. Ad ogni passo la macchina di Turing:

- Legge il simbolo sotto la testina.
- Modifica il proprio stato interno.
- Scrive un nuovo simbolo nella cella.
- Muove la testina a destra o a sinistra.

Questo modello è fondamentale per lo studio della calcolabilità ma è troppo dettagliato per l'analisi.

2.1.2 Random Access Machine (RAM)

Memoria

La memoria è costituita da un numero infinito di celle di dimensione finita a cui si accede, indipendentemente dalla posizione, in tempo costante.

Processore (singolo)

Un insieme di istruzioni simili a quelle reali: algebriche, logiche e di salto.

Costo delle istruzioni elementari

Uniforme e ininfluente ai fini dell'analisi.

2.2 Funzioni di costo, analisi asintotica

Per studiare la complessità di un algoritmo si analizza il suo comportamento asintotico, ovvero quando la dimensione del suo input tende a infinito.

2.2.1 Notazione O

Sia g(n) una funzione di costo, si indica con O(g(n)) l'insieme delle funzioni f(n) tali per cui:

$$\exists c > 0, \exists m \geq 0 : f(n) \leq cg(n), \forall n \geq m$$

g(n) si dice limite asintotico superiore di f(n), ovvero f(n) cresce al più come g(n).

2.2.2 Notazione Ω

Sia g(n) una funzione di costo, si indica con $\Omega(g(n))$ l'insieme delle funzioni f(n) tali per cui:

$$\exists c > 0, \exists m \geq 0 : f(n) \geq cg(n), \forall n \geq m$$

g(n) si dice limite asintotico inferiore di f(n), ovvero f(n) cresce almeno quanto g(n).

2.2.3 Notazione Θ

Sia g(n) una funzione di costo, si indica con $\Theta(g(n))$ l'insieme delle funzioni f(n) tali per cui:

$$\exists c_1 > 0, \exists c_2 > 0, \exists m \ge 0 : c_1 g(n) \le f(n) \le c_2 g(n), \forall n \ge m$$

f(n) cresce esattamente come g(n) e $f(n) = \Theta(g(n))$ se e solo se f(n) = O(g(n)) e $f(n) = \Omega(g(n))$.

2.2.4 Proprietà della notazione asintotica

Espressioni polinomiali

Enunciato

$$f(n) = a_k n^k + a_{k-1} n^{k-1} + \dots + a_1 n + a_0, a_k > 0 \Rightarrow f(n) = \Theta(n^k)$$

Limite superiore

$$\exists c > 0, \exists m > 0 : f(n) < cn^k, \forall n > m$$

Dimostrazione

$$f(n) = a_k n^k + a_{k-1} n^{k-1} + \dots + a_1 n + a_0$$

$$\leq a_k n^k + |a_{k-1}| n^{k-1} + \dots + |a_1| n + |a_0|$$

$$\leq a_k n^k + |a_{k-1}| n^k + \dots + |a_1| n^k + |a_0| n^k \qquad \forall n \geq 1$$

$$= (a_k + |a_{k-1}| + \dots + |a_1| + |a_0|) n^k$$

$$\stackrel{?}{\leq} c n^k$$

Vera per $c \ge (a_k + |a_{k-1}| + \dots + |a_1| + |a_0|)$ e per m = 1.

Limite inferiore

$$\exists d > 0, \exists m \geq 0 : f(n) \geq dn^k, \forall n \geq m$$

Dimostrazione

$$f(n) = a_k n^k + a_{k-1} n^{k-1} + \dots + a_1 n + a_0$$

$$\geq a_k n^k - |a_{k-1}| n^{k-1} - \dots - |a_1| n - |a_0|$$

$$\geq a_k n^k - |a_{k-1}| n^{k-1} - \dots - |a_1| n^{k-1} - |a_0| n^{k-1} \qquad \forall n \geq 1$$

$$= (a_k + |a_{k-1}| + \dots + |a_1| + |a_0|) n^k$$

$$\stackrel{?}{\geq} dn^k$$

Vera per $d \le a_k - \frac{|a_{k-1}|}{n} - \frac{|a_{k-2}|}{n} - \dots - \frac{|a_1|}{n} - \frac{|a_0|}{n} > 0 \Leftrightarrow n > \frac{|a_{k-1} + \dots + |a_0|}{a_k}.$

Dualità

Enunciato

$$f(n) = O(g(n)) \Leftrightarrow g(n) = \Omega(f(n))$$

Dimostrazione

$$\begin{split} f(n) &= O(g(n)) \Leftrightarrow f(n) \leq cg(n), \forall n \geq m \\ &\Leftrightarrow g(n) \geq \frac{1}{c}f(n), \forall n \geq m \\ &\Leftrightarrow g(n) \geq c' = f(n), \forall n \geq m, c' = \frac{1}{c} \\ &\Leftrightarrow g(n) = \Omega(f(n)) \end{split}$$

Eliminazione delle costanti

Enunciato

$$f(n) = O(g(n)) \Leftrightarrow af(n) = O(g(n)), \forall a > 0$$
(2.1)

$$f(n) = \Omega(g(n)) \Leftrightarrow af(n) = \Omega(g(n)), \forall a > 0$$
 (2.2)

Dimostrazione

$$\begin{split} f(n) &= O(g(n)) \Leftrightarrow f(n) \leq cg(n), \forall n \geq m \\ &\Leftrightarrow af(n) \leq acg(n), \forall n \geq m, \forall a \geq 0 \\ &\Leftrightarrow af(n) \leq c'g(n), \forall n \geq m, c' = ac > 0 \\ &\Leftrightarrow af(n) = O(g(n)) \end{split}$$

La dimostrazione è analoga per il limite inferiore.

Sommatoria

Enunciato

$$f_1(n) = O(g_1(n)), f_2(n) = O(g_2(n)) \Rightarrow f_1(n) + f_2(n) = O(\max(g_1(n), g_2(n)))$$

$$f_1(n) = \Omega(g_1(n)), f_2(n) = \Omega(g_2(n)) \Rightarrow f_1(n) + f_2(n) = \Omega(\min(g_1(n), g_2(n)))$$

Dimostrazione

$$f_{1}(n) = O(g_{1}(n)) \land f_{2}(n) = O(g_{2}(n)) \Rightarrow$$

$$f_{1}(n) \leq c_{1}g_{1}(n) \land f_{2}(n) \leq c_{2}g_{2}(n) \Rightarrow$$

$$f_{1}(n) + f_{2}(n) \leq c_{1}g_{1}(n) + c_{2}g_{2}(n) \Rightarrow$$

$$f_{1}(n) + f_{2}(n) \leq \max(c_{1}, c_{2})(2\max(g_{1}(n), g_{2}(n))) \Rightarrow$$

$$f_{1}(n) + f_{2}(n) = O(\max(g_{1}(n), g_{2}(n))$$

La dimostrazione è analoga per il limite inferiore.

Prodotto

$$f_1(n) = O(g_1(n)), f_2(n) = O(g_2(n)) \Rightarrow f_1(n) \cdot f_2(n) = O(g_1(n) \cdot g_2(n))$$
$$f_1(n) = \Omega(g_1(n)), f_2(n) = \Omega(g_2(n)) \Rightarrow f_1(n) \cdot f_2(n) = \Omega(g_1(n) \cdot g_2(n))$$

Dimostrazione

$$f_{1}(n) = O(g_{1}(n)) \land f_{2}(n) = O(g_{2}(n)) \Rightarrow$$

$$f_{1}(n) \leq c_{1}g_{1}(n) \land f_{2}(n) \leq c_{2}g_{2}(n) \Rightarrow$$

$$f_{1}(n) \cdot f_{2}(n) \leq c_{1}c_{2}g_{1}(n)g_{2}(n) \Rightarrow$$

$$f_{1}(n)f_{2}(n) = O(g_{1}(n)g_{2}(n))$$

Simmetria

Enunciato

$$f(n) = \Theta(g(n)) \Leftrightarrow g(n) = \Theta(f(n))$$

Dimostrazione Grazie alla proprietà di dualità:

$$\begin{array}{lll} f(n) = \Theta(g(n)) \Rightarrow & f(n) = O(g(n)) \Rightarrow & g(n) = \Omega(f(n)) \\ f(n) = \Theta(g(n)) \Rightarrow & f(n) = \Omega(g(n)) \Rightarrow & g(n) = O(f(n)) \end{array}$$

Transitività

Enunciato

$$f(n) = O(g(n)), g(n) = O(h(n)) \Rightarrow f(n) = O(h(n))$$

Dimostrazione

$$f(n) = O(g(n)) \land g(n) = O(h(n)) \Rightarrow$$

$$f(n) \le c_1 g(n) \land g(n) \le c_2 h(n) \Rightarrow$$

$$f(n) \le c_1 c_2 h(n) \Rightarrow$$

$$f(n) = O(h(n))$$

2.2. FUNZIONI DI COSTO, ANALISI ASINTOTICA

Logaritmi

Enunciato Si vuole provare che $\log n = O(n)$. Si dimostri pertanto per induzione che:

$$\exists c > 0, \exists m \ge 0 : \log n \le cn, \forall n \ge m$$

Dimostrazione

- Caso base, n = 1: $\log 1 = 0 \le cn = c\dot{1} \Leftrightarrow c \ge 0$.
- Ipotesi induttiva: sia $\log k \le ck, \forall k \le n$.
- Passo induttivo: si dimostri la proprietà per n+1.

$$\log(n+1) \leq \log(n+n) = \log 2n \qquad \forall n \geq 1$$

$$= \log 2 + \log n \qquad \log ab = \log a + \log b$$

$$= 1 + \log n \qquad \log 2 = 1$$

$$\leq 1 + cn \qquad \text{per induzione}$$

$$\stackrel{?}{\leq} c(n+1) \qquad \text{obiettivo}$$

$$1 + cn \leq c(n+1) \Leftrightarrow c \geq 1$$

2.2.5 Notazioni o, ω

Notazione o

Sia g(n) una funzione di costo, si indica con o(g(n)) l'insieme delle funzioni f(n) tali per cui:

$$\forall c, \exists m : f(n) < cg(n), \forall n \geq m$$

Notazione ω

Sia g(n) una funzione di costo, si indica con $\omega(g(n))$ l'insieme delle funzioni f(n) tali per cui:

$$\forall c, \exists m : f(n) > cg(n), \forall n \geq m$$

Significato

Utilizzando il concetto di limite si noti come:

•
$$\lim_{x \to \infty} \frac{f(n)}{g(n)} = 0 \Rightarrow f(n) = o(g(n)).$$

•
$$\lim_{x \to \infty} \frac{f(n)}{g(n)} \neq 0 \Rightarrow f(n) = \Theta(g(n)).$$

•
$$\lim_{x \to \infty} \frac{f(n)}{g(n)} = \infty \Rightarrow f(n) = \omega(g(n)).$$

•
$$f(n) = o(g(n)) \Rightarrow f(n) = O(g(n))$$
.

•
$$f(n) = \omega(q(n)) \Rightarrow f(n) = \Omega(q(n)).$$

2.2.6 Classificazione delle funzioni

Espandendo le relazioni dimostrate è possibile ottenere un ordinamento delle principali espressioni. Si consideri per ogni r < s, h < k, a < b:

$$O(1) \subset O(\log^r n) \subset O(\log^s n) \subset O(n^h) \subset O(n^h \log^r n)$$
$$\subset O(n^h \log^s n) \subset O(n^k) \subset O(a^n) \subset O(b^n)$$

2.3 Ricorrenze

Definizioni

- Equazione di ricorrenza: calcolare la complessità di un algoritmo ricorsivo richiede le creazione di un'equazione di ricorrenza, una formula matematica definita in maniera ricorsiva.
- Forma chiusa: l'obiettivo è partire dall'equazione di ricorrenza e trasformarla in una forma chiusa in modo da comprendere la classe di complessità dell'algoritmo.

2.3.1 Analisi per livelli

Questo metodo di risoluzione delle equazioni ricorsive detto anche metodo dell'albero di ricorsione consiste nell'espandere la ricorrenza in un albero i cui nodi rappresentano i costi ai vari livelli della ricorsione considerando poi il livello più basso in cui tutte le chiamate sono state ricondotte al caso base. Si otterrà pertanto una sommatoria da cui si potrà derivare la forma chiusa e la classe di complessità.

2.3.2 Metodo della sostituzione

Questo metodo di risoluzione delle equazioni ricorsive, detto anche metodo per tentativi, consiste nel cercare di indovinare una soluzione in base alla propria esperienza e di tentare di dimostrare tale soluzione per induzione.

2.3.3 Metodo delle ricorrenze comuni

Questo metodo di risoluzione delle equazioni ricorsive, detto anche metodo dell'esperto, mette a disposizione dei teoremi che permettono di risolvere facilmente ampie classi di equazioni di ricorrenza.

Ricorrenze lineari con partizione bilanciata

Teorema Siano a e b costanti intere tali che $a \ge 1$ e $b \ge 2$ e c e β costanti reali tali che c > 0 e $\beta \ge 0$. Sia T(n) l'equazione di ricorrenza nella forma:

$$T(n) = \begin{cases} aT(\frac{n}{b}) + cn^{\beta} & n > 1\\ d & n \le 1 \end{cases}$$

2.4. RELAZIONE TRA COMPLESSITÀ DI UN PROBLEMA E DI UN ALGORITMO

Posto $\alpha = \frac{\log a}{\log b} = \log_b a$ allora:

$$T(n) = \begin{cases} \Theta(n^{\alpha}) & \alpha > \beta \\ \Theta(n^{\alpha} \log n) & \alpha = \beta \\ \Theta(n^{\beta}) & \alpha < \beta \end{cases}$$

Estensione delle ricorrenze lineari con partizione bilanciata

Sia $a \ge 1, b > 1$ e f(n) asintoticamente positiva e sia

$$T(n) = \begin{cases} aT(\frac{n}{b}) + f(n) & n > 1\\ d & n \le 1 \end{cases}$$

Sono dati tre casi.

- $\exists \varepsilon > 0 : f(n) = O(n^{\log_b a \varepsilon}) \Rightarrow T(n) = \Theta(n^{\log_b a}).$
- $f(n) = \Theta(n^{\log_b a}) \Rightarrow T(n) = \Theta(f(n) \log n)$.
- $\exists \varepsilon > 0 : f(n) = \Omega(n^{\log_b a + \varepsilon}) \wedge \exists c : 0 < c < 1, \exists m > 0 : af(\frac{n}{b}) \le cf(n), \forall n \ge m \Rightarrow T(n) = \Theta(f(n)).$

Ricorrenze lineari di ordine costante

Siano a_1, \ldots, a_n costanti intere non negative, con h costante positiva, c > 0 e $\beta \ge 0$ costanti reali e T(n) una relazione di ricorrenza nella forma:

$$T(n) = \begin{cases} \sum_{1 \le i \le h} a_i T(n-i) + c n^{\beta} & n > m \\ \Theta(1) & n \le m \le h \end{cases}$$

Posto $a = \sum_{1 \le i \le h} a_i$ allora:

- $T(n) = \Theta(n^{\beta+1})$ se a = 1.
- $T(n) = \Theta(a^n n^\beta)$ se $a \ge 2$.

2.4 Relazione tra complessità di un problema e di un algoritmo

Un problema ha complessità O(f(n)) se esiste un algoritmo che lo risolve con complessità O(f(n)). Un problema ha complessità $\Omega(f(n))$ se tutti gli algoritmi che lo risolvono hanno complessità $\Omega(f(n))$.

2.4.1 Complessità in tempo di un algoritmo

La quantità di tempo richiesta per input di dimensione n:

- O(f(n)): per tutti gli input l'algoritmo costa al più f(n).
- $\Omega(f(n))$: per tutti gli input l'algoritmo costa almeno f(n).
- $\Theta(f(n))$: per tutti gli input l'algoritmo richiede f(n).

2.4.2 Complessità in tempo di un problema computazionale

La quantità di tempo richiesta per input di dimensione n:

- O(f(n)): complessità del miglior algoritmo che risolve il problema.
- $\Omega(f(n))$: dimostrare che nessun algoritmo può risolvere il problema in un tempo inferiore a $\Omega(f(n))$.
- $\Theta(f(n))$: algoritmo ottimo.

2.5 Valutare algoritmi in base alla tipologia di input

In alcuni casi gli algoritmi si comportano in maniera diversa in base a caratteristiche dell'input. Conoscerle in anticipo permette di scegliere il miglior algoritmo per la situazione.

2.5.1 Tipologie di analisi

- Analisi del caso pessimo: il tempo di esecuzione è il limite superiore al tempo di esecuzione per un qualisasi input.
- Analisi del caso medio: molto difficile in quanto si deve trovare una distribuzione uniforme degli input.
- Analisi del caso ottimo: ha senso se si conoscono caratteristiche dell'input.

2.5.2 Algoritmi di ordinamento

Il problema di ordinamento è rappresentato da una sequenza $A = a_1, \ldots, a_n$ di valori in input e dà in output una sequenza $B = b_1, \ldots, b_n$ permutazione di B tale per cui $\forall 0 < i < n-1, b_i \le b_{i+1}$.

Selection sort

Cerco il minimo e lo metto nella posizione corretta, riducendo il problema ai restanti n-1 valori.

: selectionSort(item [] A, int n) for i = 1 to n-1 do | int min = min(A, i, n)

```
: min(item []/A, int i, int n)
```

 $A[i] \leftrightarrow A[min]$

```
%Posizione del minimo parziale int min = i for j=i+1 to n do if A[j] \leq A[min] then with which will be min = j return min
```

Complessità

$$\sum_{i=1}^{n-1} (n-i) = \sum_{i=1}^{n-1} i = \frac{n(n-1)}{2} = n^2 - \frac{n}{2} = O(n^2)$$

InsertionSort

Algoritmo efficiente per ordinare piccoli insiemi. In cui si prende l'i-esimo elemento e lo si mette nella posizione corretta rispetto agli elementi precedenti, proseguendo fino alla fine.

: insertionSort(item // A, int n)

```
\begin{array}{l} \textbf{for } i=2 \ \textbf{to} \ n \ \textbf{do} \\ & \textbf{item } \textbf{temp} = \textbf{A[i]} \\ & \textbf{int } \textbf{j} = \textbf{i} \\ & \textbf{while } j>1 \ \textbf{and } A[j\text{-}1] > temp \ \textbf{do} \\ & A[\textbf{j}] = A[\textbf{j}-1] \\ & L \ \textbf{j} = \textbf{j} \\ & A[\textbf{j}] = \textbf{temp} \end{array}
```

Correttezza e complessità DA COMPLETARE

MergeSort

Il merge Sort si basa sulla tecnica di divide-et-impera in quanto divide il vettore di n elementi in due sotto vettori di $\frac{n}{2}$ elementi, chiama il merge Sort ricorsivamente su quei due elementi e unisce (merge) le due sequenze ordinate. Si sfrutta il fatto che i due sottovettori sono già ordinati per ordinare più velocemente.

```
: merge(item // A, int first, int last, int mid)
 int i, j, k , h
 i = first
 j = mid + 1
 k = first
 while i \leq mid and j \leq last do
     if A[i] \leq A[j] then
        B[k] = A[i]
       i += 1
     else
        B[k] = A[j]
      _ j += 1
    k += 1
 i = last
 for h = mid down to i do
    A[j] = A[h]
  j -= 1
 for j = first to k-1 do
  A[j] = B[j]
```

merge()

Costo computazionale O(n)

mergeSort()

```
: mergeSort(item [] A, int first, int last)

if first < last then

int mid = \lfloor \frac{first + last}{2} \rfloor

mergeSort(A, first, mid)

mergeSort(A, mid + 1, last)

merge(A, first, last, mid)
```

Costo computazionale Si assuma per semplificare che $n = 2^k$ in modo che $k = \log n$ e tutti i sottovettori hanno dimensioni di potenze esatte di due.

Si ottiene così l'equazione di ricorrenza:

$$T(n) = \begin{cases} c & n = 1\\ 2T(\frac{n}{2}) + dn & n > 1 \end{cases}$$

Si noti come ad ogni chiamata ricorsiva si svolga un'operazione di merge di costo O(1) e k vari tra 0 e $\log n$. Si ottiene pertanto $O(\sum_{i=0}^k s^i \frac{n}{2^i}) = O(\sum_{i=0}^k n) = O(kn) \Leftrightarrow O(n \log n)$.

2.6 Analisi ammortizzata

Si intende per analisi ammortizzata una tecnica di analisi di complessità che valuta il tempo per eseguire nel caso pessimo una sequenza di operazioni su una struttura dati. Esistono operazioni più o meno costose e se le operazioni costose sono meno frequenti allora il loro costo può essere ammortizzato da quelle meno costose. A differenza dell'analisi del caso medio è deterministica su operazioni multiple e verifica il caso pessimo.

2.6.1 Metodi per l'analisi ammortizzata

Metodo dell'aggregazione

In questo metodo si calcola la complessità T(n) per eseguire n operazioni in sequenza nel caso pessimo. Grazie alla sequenza si considera l'evoluzione della struttura dati data una sequenza di operazioni, considerando la sequenza pessima e sommando insieme tutte le complessità individuali. Successivamente questo T(n) viene diviso per il numero di operazioni in modo da verificare la complessità ammortizzata di un'operazione nella sequenza.

Metodo degli accantonamenti

Alle operazioni vengono assegnati costi ammortizzati che possono essere minori o maggiori del loro costo effettivo. Questa differenza è dovuta al fatto che le operazioni meno costose vengono caricate di un costo aggiuntivo detto credito: $costo \ ammortizzato = costo \ effettivo + credito \ prodotto.$ Questo credito accumulato viene speso dalle operazioni più costose: $costo \ ammortizzato = costo \ effettivo - credito \ consumato.$ Si deve dimostrare che la somma dei costi ammortizzato a_i è un limite superiore alla somma dei costi effettivi: $\sum_{i=1}^n c_i \le$

 $\sum_{i=1}^{n} a_i$ e che il valore così ottenuto è "poco costoso". Considerando il caso pessimo, la dimostrazione deve valere per tutte le sequenze e il credito dopo la t-esima operazione deve essere sempre positivo: $\sum_{i=1}^{t} a_i \leq \sum_{i=1}^{t} c_i \geq 0$.

Metodo del potenziale

Lo stato del sistema viene descritto attraverso una funzione di potenziale $\Phi(D)$. Le operazioni meno costose devono incrementare $\Phi(D)$ e quelle più costose decrementarlo. Il costo ammortizzato è pari al costo effettivo sommato alla differenza di potenziale: $a_i = c_i + \Phi(D_i) - \Phi(D_{i-1})$. Per una sequenza di operazioni di lunghezza n, se $\Phi(D_n) - \Phi(D_0) \geq 0$ il costo ammortizzato A è un limite superiore al costo reale.

Capitolo 3

Strutture dati

Si intende per dato in un linguaggio di programmazione un valore che una variabile può assumere. Un tipo di dato astratto è una collezione di valori e un insieme di operazioni ammesse su quei valori. Si dicono primitivi i tipi di dati forniti direttamente dal linguaggio di programmazione. La definizione di un tipo di dato astratto si divide nella specifica, una descrizione di alto livello di come può essere utilizzata e nell'implementazione, la realizzazione vera e propria di basso livello. Le strutture dati sono collezioni di dati, caratterizzate dall'organizzazione della collezione stessa più che dal tipo di dati contenuti. Le strutture dati sono caratterizzate da un insieme di operatori che permettono di manipolarne la struttura e un modo sistematico per organizzare l'insieme di dati. Le strutture dati si dividono in:

- Lineari o non lineari rispetto alla presenza o meno di una sequenza.
- Statiche o dinamiche se la dimensione della struttura può variare o meno.
- Omogenee o disomogenee se possono contenere uno o diversi tipi di dati.

3.1 Sequenza

Una sequenza è una struttura dati dinamica, lineare che rappresenta una sequenza ordinata di valori, dove un valore può comparire più di una volta. È importante l'ordine all'interno della sequenza.

Operazioni ammesse

- Data una posizione è possibile aggiungere o eliminare un elemento in quella posizione. Si considerano anche per comodità le posizioni pos_0 e pos_{n+1} .
- È possibile accedere direttamente alla testa e alla coda della sequenza.
- È possibile accedere sequenzialmente a tutti gli altri elementi.

Specifica

```
: Sequence
 \%Restituisce True se la sequenza è vuota
 boolean isEmpty()
 %Restituisce True se p è uguale a pos_0 o a pos_{n+1}
 boolean finished(Pos p)
 \%Restituisce la posizione del primo elemento
 Pos head()
 \%Restituisce la posizione dell'ultimo elemento
 Pos tail()
 \% {\tt Restituisce} la posizione dell'elemento che segue p
 Pos next(Pos p)
 \%Restituisce la posizione dell'elemento che precedep
 Pos prev(Pos p)
 \%Inserisce l'elemento v di tipo ttem nella posizione p
 \%Restituisce la posizione del nuovo elemento che diventa predecessore di
 Pos insert(Pos p, Item v)
 \%Rimuove l'elemento alla posizione p
 \%Restituisce la posizione del successore di p
 \%Che diventa il successore del predecessore di p
 Pos remove (Pos p)
 \%Legge l'elemento di tipo ltem contenuto nella posizione p
 Item read(Pos p)
 \%Scrive l'elemento v di tipo ltem nella posizione p
 write(Pos p, Item v)
```

3.2 Insiemi

Per insieme si intende una struttura dati dinamica, non lineare che memorizza una collezione non ordinata di elementi senza valori ripetuti. L'ordinamento tra i valori sarà dato dall'eventuale relazione d'ordine definita sul tipo di elementi stessi.

Operazioni ammesse

- Operazioni base:
 - Inserimento.
 - Cancellazione.
 - Verifica contenimento.
- Operazioni di ordinamento:
 - Massimo.
 - Minimo.
- Operazioni insiemistiche:
 - Unione.
 - Intersezione.
 - Differenza.
- Iteratori.
 - for each $x \in S$ do.

Specifica

```
: Set

%Restituisce la cardinalità dell'insieme
int size()

%Restituisce True se x è contenuto nell'insieme
boolean contains(Item x)

%Inserisce x nell'insieme se non è già presente
insert(Item x)

%Rimuove x dall'insieme se è presente
remove(Item x)

%Restituisce un nuovo insieme che è l'unione di A e B
Set union(Set A, Set B)

%Restituisce un nuovo insieme che è l'intersezione di A e B
Set intersection(Set A, Set B)

%Restituisce un nuovo insieme che è la differenza tra A e B
Set Difference(Set A, Set B)
```

3.3 Dizionari

Un dizionario è una struttura dati che rappresenta il concetto matematico di relazione univoca $R:D\to C$ o associazione chiave-valore. L'insieme D è il dominio ed è costituito dalle chiavi, l'insieme C è il codominio ed è costituito dai valori.

Operazioni ammesse

- Ottenere il valore associato ad una particolare chiave se presente altrimenti nil.
- Inserire una nuova associazione chiave-valore cancellando eventualmente associazioni precedenti per la stessa chiave.
- Rimuovere un'associazione chiave-valore esistente.

Specifica

```
: Dictionary

%Restituisce il valore associato alla chiave k se presente, nil
   altrimenti
Item lookup(Item k)

%Associa il valore v alla chiave k
  insert(Item k, Item v)

%Rimuove l'associazione della chiave k
  remove(Item k)
```

3.4 Alberi e grafi

3.4.1 Alberi ordinati

Un albero ordinato è dato da un insieme finito di elementi detti nodi, uno dei quali è designato come radice e i rimanenti, se esistono sono partizionati in insiemi ordinati e disgiunti, anch'essi alberi ordinati.

3.4.2 Grafi

La struttura di un grafo è composta da un insieme di elementi detti nodi o vertici e un insieme di coppie (ordinate o no) di nodi detti archi.

3.4.3 Operazioni

Tutte le operazioni su grafi e alberi ruotano intorno alla possibilità di effettuare visite su di essi.

3.5 Lista

Una lista o linked list è una struttura dati contenente una sequenza di nodi contenente dati arbitrari, 1-2 puntatori all'elemento successivo e/o a quello precedente. La contiguità nella lista è diversa dalla contiguità in memoria e tutte le operazioni su una lista hanno costo O(1).

Possibili implementazioni

Bidirezionale o monodirezionale: in base al numero di puntatori e se puntano a quello successivo e/o a quello precedente. Con sentinella o senza sentinella: in base alla presenza di una sentinella, una struttura che punta sempre al primo elemento della lista. Circolare o non circolare: si dice circolare se il puntatore dell'ultimo elemento punta al primo invece di essere nil.

Lista bidirezionale con sentinella

```
: List
                                         boolean finished(Pos p)
  List pred %Predecessore
 List succ %Successore
                                            return (p = this)
 Item value %Valore
                                         Item read(Pos p)
  List List()
                                            return p.value
     List t=new List
                                         Item write(Pos p, Item v)
     t.pred = t
                                           p.value = v
     t.succ = t
     return t
                                         Pos insert (Pos p, Item v)
                                            List t = List()
  boolean isEmpty()
                                             t.value = v
  return pred = succ = this
                                             t.pred = p.pred
  Pos head()
                                             p.pred.succ = t
  return succ
                                             t.succ = p
  Pos tail()
                                             p.pred = t
   return pred
                                            return t
  Pos next (Pos p)
                                         Pos remove (Pos p)
  return p.succ
                                             p.pred.succ = p.succ
                                             p.succ.pred = p.pred
  Pos prev(Pos p)
                                             List t = p.succ
  return p.pred
                                             delete p
                                             \mathbf{return} \ \mathbf{t}
```

3.6 Pila

Una pila o stack è una struttura dati lineare e dinamica in cui l'elemento rimosso dall'operazione di cancellazione è determinato, ovvero quello che per meno tempo è rimasto nell'insieme (LIFO: last-in, first-out). Possibili implementazioni sono una lista bidirezionale con un puntatore all'elemento top o tramite vettore, con dimensione limitata ma overhead più basso.

Specifica

```
: Stack

%Restituisce True se la pila è vuota
boolean isEmpty()
%Inserisce v in cima alla pila
push(Item v)
%Estrae l'elemento in cima alla pila e lo restituisce
Item pop()
%Legge l'elemento in cima alla pila
Item top()
```

Lista basata su vettore

```
: Stack
  Item [] A %Elementi
                                                boolean isEmpty()
 \mathbf{int}\ n\ \%\mathtt{Cursore}
                                                 return n=0
  int m %Dimensione massima
                                                ltem pop()
  Stack Stack(int dim)
                                                    precondition: n > 0
      \mathsf{Stack}\ \mathsf{t} = \mathbf{new}\ \mathsf{Stack}
                                                    Item t = A[n]
      t.A = new int [1...dim]
                                                    n = n - 1
      t.m = dim
                                                    \mathbf{return}\ \mathbf{t}
     t.n = 0
                                                push(Item v)
     return t
                                                    precondition: n < m
  ltem top()
                                                    n = n + 1
      precondition: n > 0
                                                    A[n] = v
      return A[n]
```

3.7 Coda

Una coda è una struttura dati lineare e dinamica in cui l'elemento rimosso dall'operazione di cancellazione è determinato, ovvero quello che per più tempo

è rimasto nell'insieme (FIFO: first-in, first-out, questo tipo di politica si dice fair). Si può implementare attraverso liste monodirezionali con il puntatore head per l'estrazione e il puntatore tail per l'inserimento o tramite array circolari, con dimensione limitata ma overhead più basso. Per i secondi la circolarità è ottenuta attraverso l'operazione modulo e si deve prestare attenzione ai problemi di overflow.

Specifica

```
: Queue

%Restituisce True se la coda è vuota
boolean isEmpty()
%Inserisce v in fondo alla coda
enqueue(ltem v)
%Estrae l'elemento in testa alla coda e lo restituisce
ltem dequeue()
%Legge l'elemento in testa alla coda
ltem top()
```

Coda basata su vettore circolare

```
: Queue
  Item [] A %Elementi
                                          boolean isEmpty()
 int n %Dimensione attuale
                                            return n=0
  int testa %Testa
                                          ltem dequeue()
 {\bf int}\ {\bf m}\ \%Dimensione massima
                                             precondition: n > 0
  Queue Queue (int dim)
                                             Item t = A[testa]
     Queue t = \mathbf{new} Queue
                                             testa = (testa + 1) \mod m
     t.A = new int [1...dim - 1]
                                             n = n - 1
     t.m = dim
                                             return t
     t.testa = 0
                                          enqueue (Item v)
     t.n = 0
                                             precondition: n < m
     return t
                                             A[(testa + n) \mod m] = v
  ltem top()
                                             n = n + 1
     precondition: n > 0
     return A[testa]
```

Capitolo 4

Alberi

4.1 Alberi radicati

Un albero radicato può essere definito in due modi.

4.1.1 Definizioni

Definizione chiusa

Un albero radicato consiste in una serie di nodi e un insieme di archi orientati che connettono coppie di nodi con le seguenti proprietà:

- Un nodo dell'albero è designato come radice.
- $\bullet\,$ Ogni nodo n,a parte la radice ha esattamente un arco entrante.
- Esiste un cammino unico dalla radice ad ogni nodo.
- L'albero è connesso.

Definizione ricorsiva

Un albero radicato è dato da:

- Un insieme vuoto.
- Un nodo radice e zero o più sottoalberi ognuno dei quali è un albero, la radice è connessa alla radice di ogni sottoalbero con un arco orientato.

4.1.2 Terminologia

- Il nodo senza archi entranti è detto radice (root).
- Per generare i sottoalberi (subtrees) da un albero si elimina la radice e tutti i suoi archi uscenti.

- Nodi con lo stesso genitore sono detti fratelli (siblings).
- Considerando un arco, il nodo da cui parte è detto genitore (parent) del nodo in cui arriva, detto figlio (child).
- I nodi senza archi uscenti sono detti foglie (leaves).
- I nodi nè foglie nè radice sono detti interni (internal nodes).
- La lunghezza del cammino semplice dalla radice ad un nodo, misurato nel numero di archi è detto profondità (depth) del nodo.
- I nodi alla stessa profondità formano un insieme chiamato livello (level).
- La profondità massima dell'albero si dice altezza (height).

4.2 Visite di alberi

La visita di un albero o ricerca è una strategia per visitare tutti i nodi di un albero. Il costo computazionale di una visita su un albero su n nodi è $\Theta(n)$ in quanto ogni nodo viene visitato un'unica volta.

4.2.1 Visita in profondità

La visita in profondità o depth-first-search (dfs) si compie visitando ricorsivamente tutti i sottoalberi dell'albero, richiede uno stack ed esiste in tre varianti: pre, in e post order.

4.2.2 Visita in ampiezza

La visita in ampiezza o breadth-fisrt-search (bfs) visita completamente ogni livello prima di passare al successivo partendo dalla radice. Richiede una queue.

4.3 Albero binario

Un albero binario è un albero radicato in cui ogni nodo ha al massimo due figli, indicati con figlio destro e sinistro. Due alberi binari differiscono anche se uno stesso nodo è designato come figlio sinistro invece che destro o viceversa.

4.3.1 Specifica

```
: Tree
  \%Costruisce un nuovo nodo contenente v senza figli o genitori
  Tree(Item v)
  \% {\rm Legge} il valore memorizzato nel nodo
  ltem read()
  \% {\tt Modifica} il valore memorizzato nel nodo
  write(Item v)
  \% Restituisce il padre o \operatorname{nil} se è il nodo radice
  Tree Parent()
  \% Restituisce il figlio sinistro (destro) di questo nodo o nil se assente
  Tree left()
  Tree right()
  \%Inserisce il sottoalbero radicato in t come figlio sinistro (destro) di
    questo nodo
  insertLeft(Tree t)
  insertRight(Tree t)
  \%Distrugge ricorsivamente il figlio sinistro (destro) di questo nodo
  deleteLeft()
  deleteRight()
```

4.3.2 Memorizzazione e implementazione

Ogni nodo deve memorizzare oltre al proprio valore la reference al nodo padre (parent), la reference ai figli sinistro (left) e destro (right).

Implementazione

```
: Binary tree
 Tree(ltem v)
                                            deleteLeft()
     \mathsf{Tree}\ t = \mathbf{new}\ \mathsf{Tree}
                                               if left \neq nil then
     t.parent = nil
                                                   left.deleteLeft()
     t.left = t.right = nil
                                                   left.deleteRight()
     t.value = v
                                                   left = nil
     return t
                                            deleteRight()
 insertLeft(Tree T)
                                               if right \neq nil then
     if left == nil then
                                                   right.deleteLeft()
         T.parent = this
                                                   right.deleteRight()
         left = T
                                                   right = nil
 insertRight(Tree T)
     if right == nil then
         T.parent = this
         right = T
```

4.3.3 Visita in profondità

4.4 Alberi generici

4.4.1 Specifica

```
: Tree
  \%Costruisce un nuovo nodo contenente v senza figli o genitori
 Tree(ltem v)
  \%Legge il valore memorizzato nel nodo
  ltem read()
  \% {\tt Modifica} il valore memorizzato nel nodo
  write(Item v)
  \% Restituisce il padre o \operatorname{nil} se è il nodo radice
  Tree Parent()
  \% Restituisce il primo figlio o nil se è un nodo foglia
  Tree leftmostchild()
  \%Restituisce il prossimo fratello o \operatorname{nil} se assente
  Tree rightSibling()
  \% {\tt Inserisce} il sottoalbero t come primo figlio di questo nodo
  insertChild(Tree t)
  \%Inserisce il sottoalbero t come prossimo fratello di questo nodo
  insertSibling(Tree t)
  \% {\tt Distrugge} l'albero radicato nel primo figlio
  deleteChild()
  \%Distrugge l'albero radicato nel prossimo fratello
  deleteSibling()
```

Depth-first search

Breadth-first search

4.4.2 Memorizzazione

Esistono vari modi per salvare un albero, scelti in base al numero massimo e medio dei figli presenti.

Vettore dei figli

Nel nodo viene memorizzato il genitore e un vettore contenente i figli, che a seconda del loro numero può portare a uno spreco dello spazio.

Primo figlio, prossimo fratello

```
: Tree
   Tree parent %Reference al padre
                                                    deleteChild()
                                                        Tree newChild =
   Tree child %Reference al primo figlio
                                                         child.rightSibling()
   Tree sibling %Reference al prossimo
                                                          delete(child)
     fratello
                                                        child = newChild
  Item\ value\ \% {\tt Valore\ memorizzato\ nel}
    nodo
                                                    deleteSibling()
  Tree(ltem v)
                                                        Tree newBrother =
       \mathsf{Tree}\ t = \mathbf{new}\ \mathsf{Tree}
                                                         sibling.rightSibling()
       t.value = v
                                                        delete(sibling)
       t.parent = t.child = t.sibling =
                                                        sibling = newBrother
        _{
m nil}
                                                    delete(Tree t)
      \mathbf{return} \ \mathbf{t}
                                                        \label{eq:total_total} \mathsf{Tree}\; u = t.\mathtt{leftMostChild()}
  insertChild(Tree t)
                                                        while u \neq \text{nil do}
       t.parent = self
                                                            \label{eq:total_transform} \mathsf{Tree}\ \mathrm{next} = \mathrm{u.rightSibling()}
      t.sibling = child
                                                            delete(u)
      child = t
                                                            u = next
   insertSibling(Tree t)
      t.parent = parent
       t.sibling = sibling
      sibling = t
```

Vettore dei padri

L'albero è rappresentato da un vettore i cui elementi contengono il valore associato al nodo e l'indice della posizione del padre nel vettore.

Capitolo 5

Alberi di ricerca

Si vuole portare la ricerca binaria negli alberi in modo da implementare un dizionario.

- Le associazioni chiave-valore vengono memorizzate in un albero binario.
- $\bullet\,$ Ogni nodo u contiene la coppia u.key e u.value.
- Le chiavi devono appartenere ad un insieme totalmente ordinato.

Le chiavi contenute nel sottoalbero sinistro di u sono minori di u.key e quelle contenute nel sottoalbero destro maggiori. In questo modo è possibile realizzare un algoritmo di ricerca dicotomica.

5.1 Specifica

: Search Binary Tree			
Tree parent	remove(Item k)		
Tree left	$\% {\tt Ordinamento}$		
Tree right	Tree successorNode(Tree t)		
Item value	Tree predecessorNode(Tree t)		
Item key	Tree min()		
%Getters	Tree max()		
<pre>ltem key()</pre>	%Funzioni interne		
<pre>Item value()</pre>	$\mathbf{private}$: Tree lookupNode (Tree t ,		
Tree parent()	Item k)		
Tree right()	private: Tree insertNode(Tree t ,		
Tree left()	Item k , Item v)		
%Dizionario	<pre>private: Tree removeNode(Tree t,</pre>		
Item lookup(Item k)	Item k)		
$\underline{\hspace{1cm}}$ insert(ltem k , ltem v)			

5.1. SPECIFICA

```
: Dictionary

Tree tree
Dictionary()

_ tree = nil
```

5.1.1 Ricerca

La funzione $look UpNode(Tree\ t,\ Item\ k)$ restituisce il nodo dell'albero t che contiene la chiave k o **nil** se non presente.

Implementazione nel dizionario

${\bf Implementazione}$

Iterativa

```
: Tree lookupNode (Tree t, ltem k)

Tree u = t while u \neq nil and u.key \neq k do

if k < u.key then

u = u.left else

u = u.right
```

Ricorsiva

```
: Tree lookupNode (Tree t,
ltem k)

if t == nil or t.key == k
    then
    | return t
    else if k < t.key then
        return
        lookupNode(t.left, k)
    else
        return
        lookupNode(t.right, k)</pre>
```

5.1.2 Minimo e massimo

Implementazione

```
\begin{array}{lll} \textbf{:} \ \mathsf{Tree} \ \mathsf{min} \ (\mathsf{Tree} \ t) & \\ & \mathsf{Tree} \ \mathsf{u} = t & \\ & \mathsf{while} \ \ u.\mathsf{left}() \neq \mathsf{nil} \ \mathsf{do} & \\ & \big \lfloor \ \mathsf{u} = \mathsf{u.left} & \\ & \mathsf{return} \ \mathsf{u} & \\ \end{array} \quad \begin{array}{ll} \mathsf{:} \ \mathsf{Tree} \ \mathsf{max} \ (\mathsf{Tree} \ t) \\ & \mathsf{Tree} \ \mathsf{u} = t \\ & \mathsf{while} \ \ u.\mathsf{right} \neq \mathsf{nil} \ \mathsf{do} \\ & \big \lfloor \ \mathsf{u} = \mathsf{u.right} \\ & \mathsf{return} \ \mathsf{u} \\ \end{array}
```

5.1.3 Successore e predecessore

Si definisce successore di un nodo u il più piccolo nodo maggiore di u.

Implementazione

```
: successorNode(Tree t)
                                         : predecessorNode(Tree t)
 if t = nil then
                                           if t = nil then
  return t
                                              return t
 if t.left \neq nil then
                                           if t.right() \neq nil then
     return max(t.left)
                                              return min(t.right)
 else
                                           else
     Tree p = t.parent()
                                              Tree p = t.Parent
     while p \neq \text{nil} and t =
                                              while p \neq \text{nil} and t =
      p.left do
                                               p.right do
        t = p
                                                  t = p
        p = p.parent
                                                  p=p.\mathtt{Parent}
     return p
                                              return p
```

5.1.4 Inserimento

L'operazione $insertNode(Tree\ t,\ Item\ k,\ Item\ v)$ inserisce un'associazione chiavevalore $(k,\ v)$ nell'albero t. Se la chiave è già presente sostiutuisce il valore associato, altrimenti viene inserita una nuova associazione. Se T=nil restituisce il primo nodo dell'albero, altrimenti restituisce t inalterato.

Implementazione dizionario

```
: insert(ltem k, ltem v)

tree = insertNode(tree, k, v)
```

Implementazione

```
: Tree insertNode(Tree t, Item k, Item v)
  Tree p = nil
  \mathsf{Tree}\ u=t
  while u \neq \text{nil} and u.\text{key} \neq k do
      p = u
      if k < u.key then
          \mathbf{u} = \mathbf{u}.\mathtt{left}
      else
        u = u.right
  if u \neq \text{nil} and u.\text{key} == k \text{ then}
      u.\mathtt{value} = v
  else
      Tree new = Tree(k, v)
      link(p, new, k)
      if p = nil then
         t = new
      \mathbf{return} \ \mathbf{t}
```

5.1.5 Cancellazione

L'operazione $Tree\ removeNode(Tree\ t,\ Item\ k)$ rimuove il nodo contenente la chiave k dall'albero t e restituisce la radice dell'albero possibilmente cambiata.

Implementazione dizionario

```
: remove(Item k)
tree = removeNode(tree, k)
```

Implementazione

```
: Tree removeNode (Tree T, Item k)
  Tree t
  Tree u = lookupNode(T, k)
 if u \neq \text{nil then}
     if u.left == nil  and u.right == nil  then
        link(u.parent, nil, k)
        \mathbf{delete} u
     else if u.left \neq nil and u.right \neq nil then
        Tree s = successorNode()
        link(s.parent, s.right, s.key)
        u.key() = s.key()
        u.value() = s.value()
        delete s
     else if u.left \neq nil and u.right == nil then
        link(u.parent, s.left, k)
        if u.parent = nil then
           T = u.left
     else
        link(u.parent, s.right, k)
        if u.parent = nil then
            T = u.right
 return T
```

Dimostrazione correttezza

- Caso 1: Eliminare foglie non cambia l'ordine dei nodi rimanenti.
- Caso 2: Se u è il figlio destro (sinistro) di p, tutti i valori nel sottoalbero di f sono maggiori (minori) di p, pertanto f può essere attaccato come figlio destro (sinistro) di p al posto di u.
- Caso 3: il successore s è sicuramente \geq dei nodi del sottoalbero sinistro di u e sicuramente \leq dei nodi del sottoalbero destro di u, pertanto può essere sostituito a u e a quel punto si ricade nel caso 2.

5.2 Costo computazionale

Tutte le operazioni sono confinate ai nodi posizionati lungo un cammino semplice dalla radice ad una foglia, pertanto detta h altezza di un albero, avranno complessità O(h). Il caso pessimo si ha nel caso in cui l'altezza h sia uguale a n (O(n)), il caso ottimo quando $h = \log n$ $(O(\log n))$.

5.3 Alberi di ricerca bilanciati

Per mantenere un grado di complessità il più vicino possibile a $O(\log n)$ si utilizzano tecniche di bilanciamento per tenere sotto controllo l'altezza di un albero. Si introduce un fattore di bilanciamento $\beta(v)$, ovvero la massima differenza di altezza fra i sottoalberi di v.

- Alberi AVL: $\beta(v) \leq 1$ per ogni nodo v, bilanciamento ottenuto tramite rotazioni.
- B-Alberi: $\beta(v) = 0$ per ogni nodo v, specializzati per strutture in memoria secondaria.
- Alberi 2-3: $\beta(v) = 0$ per ogni nodo v, bilanciamento ottenuto tramite merge/split, grado variabile.

Rotazioni

Rotazione sinistra Si prende un nodo di un albero, si fa diventare suo figlio destro il figlio sinistro del figlio destro, successivamente si pone il nodo iniziale come figlio sinistro del vecchio nodo destro e il vecchio genitore del nodo iniziale diventa il genitore del vecchio nodo destro.

Rotazione destra Si prende un nodo di un albero, si fa diventare suo figlio sinistro il figlio destro del suo figlio sinistro, successivamente si pone il nodo iniziale come figlio destro del vecchio nodo sinistro e il vecchio genitore del nodo iniziale diventa il genitore del vecchio nodo sinistro.

```
: Tree rotateLeft(Tree x)
                                                       : Tree rotateRight(Tree x)
  Tree y \leftarrow x.right
                                                         Tree y \leftarrow x.left
  \mathsf{Tree}\ p \leftarrow x.\mathtt{parent}
                                                         Tree p \leftarrow x.parent
  x.right \leftarrow y.left
                                                         x.right \leftarrow y.right
  if y.left \neq nil then
                                                         if y.right \neq nil then
      y.left.parent \leftarrow x
                                                           y.right.parent \leftarrow x
  y.left \leftarrow x
                                                         y.right \leftarrow x
  x.parent \leftarrow y
                                                         x.parent \leftarrow y
  y.parent \leftarrow p
                                                         y.\mathtt{parent} \leftarrow p
  if p \neq \text{nil then}
                                                         if p \neq \text{nil then}
      if p.left == x then
                                                             if p.left == x then
          p.left \leftarrow y
                                                                  p.left \leftarrow y
                                                             else
           p.right \leftarrow y
                                                                  p.right \leftarrow y
  return y
                                                         return y
```

5.3.1 Alberi red-black

Un albero red-black è un albero binario di ricerca in cui ogni nodo è colorato di rosso o nero, le chiavi vengono salvate solo nei nodi interni all'albero e le foglie sono costituiti da nodi speciali **Nil**. Un albero red-black è costruito in modo che rispetti questi vincoli:

- La radice è nera.
- Tutte le foglie sono nere.
- Entrambi i figli di un nodo rosso sono neri.
- Tutti i cammini semplici da un nodo u a una delle foglie contenute nel sottoalbero radicato in u hanno lo stesso numero di nodi neri.

Memorizzazione

I nodi **Nil** sono nodi sentinella il cui scopo è evitare di trattare diversamente i puntatori ai nodi dai puntatori **nil**. Al posto di un puntatore **nil** si utilizza un puntatore ad un nodo speciale **Nil**. Ne esiste solo uno per risparmiare memoria e un nodo con figli **Nil** corrisponde ad una foglia nell'albero binario di ricerca.

Altezza nera

L'altezza nera b(v) di un nodo v è il numero di nodi neri lungo ogni percorso da v escluso ad ogni foglia inclusa del sottoalbero. L'altezza nera di un albero redblack è pari all'altezza nera della sua radice. Quando esistono più colorazioni che rispettano i limiti possono esistere diverse altezze nere per lo stesso albero.

Inserimento

Quando si vuole inserire un nodo in un albero red-black si ricerca la posizione usando la stessa procedura per gli alberi di ricerca e si colora il nuovo nodo di rosso. Si possono pertanto violare dei vincoli in questo modo e si rende necessario aggiungere nella funzione $insertNode(Tree\ T,\ Item\ k,\ Item\ v)$ un processo di bilanciamento (eseguito successivamente alla chiamata della funzione link). Il principio generale per il bilanciamento consiste nel spostarsi verso l'alto lungo il percorso di inserimento, ripristinare il vincolo dei figli neri di un nodo rosso spostando le violazioni verso l'alto mantenendo l'altezza nera dell'albero e colorando la radice di nero alla fine. Queste operazioni sono necessarie unicamente quando due nodi consecutivi sono rossi.

 $balanceInsert(Tree\ t)$ I nodi coinvolti sono il nodo inserito t, suo padre p, suo nonno n e suo zio z. E si possono verificare sette casi diversi in cui avviene una violazione.

- Caso 1: il nuovo nodo t non ha padre: è il primo nodo ad essere inserito o si è risaliti fino alla radice, si colora t di nero.
- Caso 2: il padre p di t è nero: non si viola nessun vincolo.
- Caso 3: t rosso, p rosso, z rosso: se z è rosso si possono colorare di nero p, z e di rosso n. Poichè tutti i cammini che passano per z e p passano per n l'altezza nera non è cambiata. Il problema ora potrebbe sussistere sul nonno, si pone pertanto t = n e il ciclo continua.
- Caso 4a (4b): t rosso, p rosso, z nero: si assuma che t sia figlio de-

- stro (sinistro) di p e p figlio sinistro (destro) di n. Una rotazione a sinistra (destra) a partire dal nodo p scambia i ruoli di t e p ottenendo il caso 5a (5b) essendo entrambi i nodi coinvolti nel cambiamento rossi, l'altezza nera non cambia.
- Caso 5a (5b): t rosso, p rosso, z nero: si assuma che t sia figlio sinistro (destro) di p e p figlio sinistro (destro) di n. Una rotazione a destra su n porta ad una situazione in cui t e n sono figli di p. Colorando n di rosso e p di nero ci si ritrova in una situazione in cui tutti i vincoli sono rispettati.

 $t \leftarrow \mathbf{nil}$

```
: balancedInsert(Tree t)
  t.\texttt{color()} \leftarrow \mathsf{RED}
  while t \neq \text{nil do}
       \textit{Tree } p \leftarrow t. \textit{parent } \% \textit{padre} \\
      Tree n %nonno
      Tree z %zio
      if p \neq \text{nil then}
        n \leftarrow p.\mathtt{parent}
      else
       n \leftarrow \mathbf{nil}
      if n == nil then
        z \leftarrow nil
      else
           if n.left == p then
            z \leftarrow p.right
           else
            z \leftarrow p.\texttt{left}
      if p == nil then
           \%Caso 1
           t.\mathtt{color} \leftarrow \mathsf{BLACK}
          t \leftarrow nil
      else if p.color == BLACK then
           %Caso 2
          t \leftarrow nil
      else if z.color == RED then
           \%Caso 3
           \texttt{p.color} \leftarrow \texttt{z.color} \leftarrow \mathsf{BLACK}
           n.color \leftarrow RED
           t \leftarrow n
      else
           if t == p.right and p == n.left then
               %Caso 4a
               rotateLeft(p)
              t \leftarrow p
           else if t == p.left and p == n.right then
               \%Caso 4b
               rotateRight(p)
               t \leftarrow p
           else
               if t == p.left and p == n.left then
                    %Caso 5a
                   rotateRight(n)
                else if t == p.right and p == n.right then
                    %Caso 5b
                   rotateLeft(n)
                p.\mathtt{color} \leftarrow \mathsf{BLACK}
                n.\mathtt{color} \leftarrow \mathsf{RED}
                                               47
```

Complessità La complessità totale per un inserimento è $O(\log n)$, con tre passaggi: $O(\log n)$ per scendere fino al punto di inserimento, O(1) per effettuare l'inserimento e $O(\log n)$ per risalire e sistemare le violazioni. È possibile implementare un inserimento top-down che aggiusta l'albero mano a mano che scende fino al punto di inserimento.

Altezza albero red-black

Teorema In un albero red-black un sottoalbero di radice u contiene almeno $n > 2^{bh(u)} - 1$ nodi interni.

Dimostrazione Si dimostra per induzione sull'altezza (non sull'altezza nera).

- Caso base h = 0: u è una foglia **nil** e il sottoalbero con radice in u contiene $n > 2^{bh(u)} 1 = 2^0 1 = 0$ nodi interni.
- Passo induttivo h > 1: allora u è un nodo interno con due figli tali che ogni figlio v ha un'altezza nera bh(v) pari a bh(u) se rosso o a bh(u) 1 se nero. Per ipotesi induttiva ogni figlio ha almeno $2^{bh(u)} 1$ nodi interni. Pertanto il sottoalbero con radice in u ha almeno $n \ge 2^{bh(u)-1} 1 + 2^{bh(u)-1} 1 + 1 = 2^{bh(u)-1} 1$ nodi.

Teorema In un albero red-black almeno la metà dei nodi dalla radice ad una foglia deve essere nera.

Dimostrazione Per il secondo vincolo se un nodo è rosso, entrambi i suoi figli devono essere neri, pertanto la situazione in cui sono presenti il maggior numero di nodi rossi è il caso in cui rossi e neri sono alternati, dimostrando il teorema.

Teorema In un albero red-black nessun percorso da un nodo v ad una foglia è lungo più del doppio del percorso da v ad un'altra foglia.

Dimostrazione Per definizione ogni percorso da un nodo ad una qualsiasi foglia contiene lo stesso numero di nodi neri. Dal lemma precedente almeno la metà di questi nodi sono neri, pertanto al limite uno dei due percorsi è costituito da soli nodi neri mentre l'altro è costituito da nodi neri e rossi alternati.

Teorema L'altezza massima di un albero red-black contenente n nodi interni è al più $2\log(n+1)$.

Dimostrazione

$$\begin{split} n & \geq 2^{bh(r)} - 1 \Leftrightarrow n \geq 2^{\frac{h}{2}} - 1 \\ & \Leftrightarrow n + 1 \geq 2^{\frac{h}{2}} \\ & \Leftrightarrow \log n + 1 \geq \frac{h}{2} \\ & \Leftrightarrow h \leq 2\log(n + 1) \end{split}$$

Cancellazione

L'algoritmo di cancellazione per gli alberi red-black è costruito su quello di cancellazione per gli alberi generici. Dopo la cancellazione è necessario decidere se ribalanciare o meno. Le operazioni di ripristino sono necessarie solo dopo la cancellazione di un nodo nero in quando se il nodo cancellato è rosso l'altezza nera rimane invariata, non sono creati nodi rossi consecutivi e la radice resta nera. Se il nodo cancellato è nero si possono rompere i vincoli uno, tre e quattro. L'algoritmo seguente ripristina i vincoli con rotazioni e cambiamenti di colore. Ci sono quattro casi possibili con i corrispettivi simmetrici.

Complessità La cancellazione è concettualmente complicata ma efficiente in quanto dal caso 1 si passa al 2, 3 o 4, dal caso 2 si passa agli altri risalendo l'albero, dal caso 3 si passa al caso 4 e al caso 4 termina. È possibile visitare un massimo di $O(\log n)$ di casi, ognuno dei quali risolti in O(1).

: balancedDelete(Tree T, Tree t) while $T \neq t$ and t.color == BLACK do $\mathsf{Tree}\ p = t.\mathtt{parent}\ \%\mathtt{Padre}$ else Tree f = p.left %Fratelloif t == p.left then Tree f = p.right %Fratello Tree ns = f.left %Nipote sinistroTree $\mathrm{ns} = \mathrm{f.left}$ %Nipote sinistro Tree nd = f.right %Nipote destro Tree $\mathrm{nd} = \mathrm{f.right} \ \% \mathtt{Nipote} \ \mathtt{destro}$ $\mathbf{if}\ \mathit{f}.\mathtt{color} == \mathsf{RED}\ \mathbf{then}$ %Caso 1b **if** f.color == RED**then** %Caso 1a p.color = RED $p.\mathtt{color} = \mathsf{RED}$ $f.\mathtt{color} = \mathsf{BLACK}$ $f.\mathtt{color} = \mathsf{BLACK}$ rotateRight(p) rotateLeft(p) %t viene lasciato inalterato, $\%\ensuremath{\text{t}}$ viene lasciato inalterato, pertanto si ricade nei casi 2, pertanto si ricade nei casi 2, 3 o 4 else 3 o 4 if ns.color == nd.color ==else if ns.color == nd.color ==BLACK then %Caso 2b BLACK then f.color = RED%Caso 2a f.color = REDt = pelse if nd.color == RED and t = pns.color == BLACK thenelse if ns.color == RED and %Caso 3b nd.color == BLACK thennd.color = BLACK%Caso 3a ns.color = BLACKf.color = REDf.color = REDrotateLeft(f) rotateRight(f) % t viene lasciato %t viene lasciato inalterato, pertanto si inalterato, pertanto si ricade nel caso 4 else if ns.color == REDricade nel caso 4 else if nd.color == REDthen %Caso 4a then f.color = p.color() %Caso 4a f.color = p.color() p.color = BLACKp.color = BLACK $\operatorname{ns.color} = \mathsf{BLACK}$

rotateRight(p)

t = T

nd.color = BLACK

rotateLeft(p)

t = T

Capitolo 6

Hashing

Le tabelle hash sono l'implementazione ideale per dizionari, insiemi dinamici di coppie chiave-valore indicizzati sulla chiave. Si sceglie una funzione hash H che mappa ogni chiave $k \in \mathcal{U}$ in un intero H(k). La coppia chiave-valore viene memorizzata in un vettore nella posizione H(k) che viene detto tabella hash.

6.0.1 Definizioni

- L'insieme delle possibili chiavi è rapprentato dall'insieme universo $\mathcal U$ di dimensione u.
- Il vettore T[0...m-1] ha dimensione m.
- Una funzione hash è definita: $H: \mathcal{U} \to \{0, \dots, m-1\}.$
- Quando due o più chiavi nel dizionario hanno lo stesso valore di hash avviene una collisione, idealmente non dovrebbero avvenire.

Tabelle ad accesso diretto

Si utilizzano le tabelle ad accesso diretto nel caso particolare in cui $\mathcal{U} \subset \mathbb{Z}^+$. Si utilizza come funzione hash l'identità H(k) = k e $m = |\mathcal{U}|$. Presenta dei problemi quando u è molto grande e uno spreco di memoria quando u non è grande ma il numero di chiavi effettivamente registrate in memoria è molto minore di m.

Funzioni hash perfette

Una funzione hash si dice perfetta se è iniettiva, ovvero $\forall k_1, k_2 \in \mathcal{U}, k_1 \neq k_2 \Rightarrow H(k_1) \neq H(k_2)$. Ci sono dei problemi in quanto lo spazio delle chiavi è spesso grande, sparso e non conosciuto ed è pertanto spesso impraticabile ottenere una funzione di hash perfetta.

6.1 Funzioni hash

Se non è possibile eliminare le collisioni si cerca per lo meno di minimizzare il loro numero, cercando funzioni che distribuiscano le chiavi uniformemente negli indici $[0, \ldots, m-1]$ della tabella hash.

Uniformità semplice

Sia P(k) la probabilità che una chiave sia inserita nella tabella. Sia Q(i) la probabilità che una chiave finisca nella cella i: $Q(i) = \sum_{k \in \mathcal{U}: h(k) = i} P(k)$. Una funzione hash gode dell'uniformità semplice se: $\forall i \in [0, \dots, m-1]: Q(i) = \frac{1}{m}$.

6.1.1 Come realizzare una funzione hash

Per realizzare una funzione hash con uniformità semplice è necessario che la distribuzione P sia nota, cosa non completamente possibile nella realtà. Si utilizzano pertanto tecniche euristiche. Pertanto si assuma che ogni chiave può essere tradotta in numeri interi non negativi anche interpretando la loro rappresentazione in memoria come un numero. Si intenda pertanto con bin(k) la rappresentazione binaria della chiave.

Estrazione

Si consideri $m = 2^p$ e H(k) = int(b), dove b è un sottoinsieme di p bit presi da bin(k). Presenta dei problemi in quanto selezionare bit presi dal suffisso della chiave può generare collisioni con alta probabilità (o anche in generale).

XOR

Si consideri $m = 2^p$ e H(k) = int(b) dove b è dato dalla somma modulo 2 effettuata bit a bit di sottoinsiemi di p bit di bin(k). Presenta dei problemi in quanto le permutazioni possono generare lo stesso valore di hash.

Metodo della divizione

Si consideri m numero dispari, meglio se primo. $H(k)=int(k)\mod m$. Non vanno bene $m=2^p$ in quanto considera unicamente i p bit meno significativi e $m=2^p-1$ in quanto permutazioni con set di elementi con dimensione 2^p hanno lo stesso valore di hash. Si devono pertanto scegliere numeri primi distanti da potenza di 2 e 10.

Metodo della moltiplicazione

Si consideri un m qualsiasi, meglio se potenza di 2, $C \in]0;1[$ una costante reale e i=int(k). $H(k)=\lfloor m(C\cdot i-\lfloor C\cdot i\rfloor)\rfloor$.

Implementazione Si scelga un valore $m=2^p$, sia w la dimensione della parola in memoria: $i, m \leq 2^w$. Sia $s = \lfloor C \cdot 2^w \rfloor$. $i \cdot s$ può essere riscritto come $r_1 \cdot 2^w + r_0$, dove r_1 contiene la parte intera di iC e r_0 la parte frazionaria. Si restituiscando i p bit più significativi di r_0 .

Reality check

Il metodo della moltiplicazione non fornisce hashing uniforme. Esistono test per valutare la bontà di una funzione hash: Avalanche effect che se si cambia un bit nella chiave, deve cambiare almeno la metà dei bit del valore hash e test statistici con il chi-quadro. Si devono implementare inoltre funzioni hash crittografiche.

6.2 Le collisioni

Per gestire le collisioni si rende necessario trovare posizioni alternative per le chiavi e se la chiave non si trova nella posizione attesa la si deve cercare nelle posizioni alternative. Questa ricerca deve essere O(1) nel caso medio e O(n) nel caso pessimo. Presentano problemi in quanto sono strutture dati complesse vista la presenza di liste e puntatori.

6.2.1 Liste o vettori di trabocco (Concatenamento o chaining)

Le chiavi con lo stesso valore di hash vengono memorizzate in una lista monodirezionale o vettore dinamico. Si memorizza un puntatore alla testa della lista nello slot H(k)-esimo della tabella hash. Le operazioni sono di inserimento in testa insert, di ricerca lookup o rimozione remove che implicano una scansione della tabella per cercare la chiave.

Analisi complessità

Si considerino i seguenti valori:

n	Numero di chiavi memorizzate nella tabella hash	
m	Capacità della tabella hash	
$\alpha = \frac{n}{m}$	fattore di carico	
$I(\alpha)$	Ricerca con insuccesso o numero medio	
	di accessi alla tabella per una chiave non presente	
$S(\alpha)$	Ricerca con successo o numero medio	
	di accessi alla tabella per una chiave presente	

Caso pessimo Tutte le chiavi sono collocate in un'unica lista: insert $\Theta(1)$, lookup(), remove() $\Theta(n)$.

Analisi del caso medio Il caso medio dipende dalla distribuzione delle chiavi, si assuma pertanto hashing uniforme semplice e costo di calcolo della funzione di hashing $\Theta(1)$. Il valore atteso della lunghezza della lista è di $\alpha = \frac{n}{m}$. Una ricerca senza successo visita tutte le chiavi nella lista corrispondente, pertanto ha costo atteso $\Theta(1) + \alpha$, mentre una ricerca con successo visita in media la metà delle chiavi nella lista corrispondente, pertanto $\Theta(1) + \frac{\alpha}{2}$. Il fattore di carico influenza il costo computazionale delle operazioni sulla tabella hash e se n = O(m), $\alpha = O(1)$, pertanto tutte le operazioni sono O(1).

6.2.2 Indirizzamento aperto

Nell'indirizzamento aperto tutte le chiavi vengono memorizzate nella tabella stessa e ogni slot contiene una chiave oppure un valore nil. Nell'inserimento se uno slot è utilizzato se ne cerca uno alternativo. Nella ricerca si cerca nello slot prescelto e poi negli slot alternativi fino a che si trova la chiave oppure un nodo nil.

Definizioni

- Un'ispezione è l'esame di uno slot durante la ricerca.
- La funzione di hash viene estesa: $H: \mathcal{U} \times [0, \dots, m-1] \to [0, \dots, m-1]$, dove il secondo insieme del dominio rappresenta il numero di ispezione metre il codominio l'indice del vettore.
- Sequenza di ispezione: una sequenza di ispezione [H(k,0), H(k,1),...,H(k,m-1)] è una permutazione degli indici corrisondente all'ordine in cui vengono visitati gli slot. Non si vogliono visitare gli slot più di una volta e potrebbe rendersi necessario visitare tutti gli slot della tabella.

Fattore di carico Il fattore di carico è compreso tra 0 e 1 e la tabella può andare in overflow.

Tecniche di ispezione

Hashing uniforme La situazione ideale prende il nome di hashing uniforme, in cui ogni chiave ha la stessa probabilità di avere come sequenza di ispezione una delle qualisasi m! permutazioni degli indici.

Ispezione lineare La funzione di $H(k,i) = (H_1(k) + h \cdot i) \mod n$. La sequenza di ispezione è determinata dal primo elemento. Al massimo m sequenze di ispezione diverse sono possibili.

Agglomerazione primaria Causa lunghe sotto-sequenze occupate che tendono a diventare più lunghe: uno slot vuoto preceduto da i slot pieni viene riempito con probabilità $\frac{i+1}{m}$. I tempi medi di inserimento e cancellazione crescono.

Ispezione quadratica La funzione di $H(k,i) = (H_1(k)+h\cdot i^2) \mod n$. Dopo il primo elemento $H_1(k,0)$, le ispezioni successive hanno un offset che dipende da una funzione quadratica nel numero di ispezione i. La sequenza risultante non è una permutazione, al massimo m sequenze di ispezioni distinte sono possibili.

Agglomerazione secondaria Se due chiavi hanno la stessa ispezione iniziale le loro sequenze sono identiche.

Doppio hashing Funzione: $H(k,i) = (H_1(k) + iH_2(k)) \mod n$. Esistono pertanto due funzioni ausiliare, H_1 fornisce la prima ispezione, H_2 fornisce l'offset rispetto alla prima ispezione. Sono possibili al massimo m^2 sequenze di ispezione. Per garantire una permutazione completa $H_2(k)$ e m devono essere primi tra loro. Pertanto se si sceglie $m = 2^p H_2(k)$ deve restituire numeri dispari. Se si sceglie m primo, $H_2(k)$ deve restituire numeri minori di m.

Cancellazione

Non si possono sostituire le chiavi da eliminare con **nil** in quanto potrebbe introdurre errori nella ricerca che terminerebbe troppo presto. Si utilizza pertanto un valore speciale **deleted** che vengono trattati come slot vuoti dal'inserimento e come slot pieni dalla ricerca. Il tempo di ricerca non dipende più da α ma il concatenamento diventa più comune.

Implementazione dell'hashing doppio

```
: Hash
 Item [] V %Tabella dei valori
 int m %Dimensione della tabella
 Hash(int dim)
     \mathsf{Hash}\ \mathsf{t} = \mathbf{new}\ \mathsf{Hash}
     t.m = dim
     t.K = new \text{ Item } [0, \dots, dim - 1] t.V = new \text{ Item } [0, \dots, dim - 1]
      for i = 0 to dim-1 do
      t.K[i] = nil
    return t
 int scan(Item k, boolean insert)
     int c = m
     int i = 0
     int j = H(k)
     while K[j] \neq k and K[j] \neq \text{nil and } i < m \text{ do}
        if K[j] == deleted and c == m then
         c = j
        j = (j + H'(k)) \mod n
       i += 1
     if insert and K[j] \neq k and c < m then
      j = c
    return j
 Item lookup(Item k)
     int i = scan(k, false)
     if K/i/==k then
        return V[i]
     else
       return nil
  insert(Item k, Item v)
     int i = scan(k, true)
     if K[i] == nil or K[i] == deleted or K[i] == k then
        K[i] = k
        V[i] = v
     else
      igspace %Errore, tabella hash piena
 remove(Item k)
     int i = scan(k, false)
     if k/i/=k then
      K[i] = deleted
```

6.3 Complessità

Metodo	α	$I(\alpha)$	$S(\alpha)$
Lineare	$0 \le \alpha < 1$	$\frac{(1-\alpha)^2+1}{2(1-\alpha)^2}$	$\frac{1-\frac{\alpha}{2}}{1-\alpha}$
Hashing doppio	$0 \le \alpha < 1$	$\frac{1}{1-\alpha}$	$-\frac{1}{\alpha}\ln(1-\alpha)$
Liste di trabocco	$\alpha \geq 0$	$1 + \alpha$	$1+\frac{\alpha}{2}$

Si noti come la complessità aumenti con l'aumentare di α . Pertanto sopra una soglia prefissata t_{α} , solitamente tra 0.5 e 0.75 si alloca una nuova dimensione 2m e si reinseriscono tutte le chiavi presenti nella tabella. Si dimezza pertanto il fattore di carico e si eliminano tutti gli elementi **deleted**. Nel caso pessimo c'è un costo di O(m) per la ristrutturazione nel caso pessimo con costo ammortizzato costante.

Capitolo 7

Insiemi e dizionari

7.1 Insiemi

7.1.1 Insiemi realizzati con vettori booleani

Implementazione

```
: Set (vettore booleano)
 boolean [] V
                                         Set union(Set A, Set B)
 int size
                                            Set C = Set(max(A.dim, B.dim))
 int dim
                                            for i = 1 to A.dim do
 Set Set(int m)
                                                if A.contains(i) then
     Set t = \mathbf{new} \mathsf{Set}
                                                 C.insert(i)
     t.size = 0
                                            for i = 1 to B.dim do
     t.dim = = m
                                                if B.contains(i) then
    t.V = [false] * m
                                                 C.insert(i)
    return t
 boolean contains(int x)
                                            return C
     if 1 \le x \le dim then
                                         Set intersection (Set A, Set B)
        return V[x]
                                            Set C = Set(min(A.dim, B.dim))
     else
                                            for i = 1 to min(A.dim, B.dim)
        return false
                                              do
                                                if A.contains(i) and
 int size()
                                                 B.contains(i) then
   \mathbf{return} \,\, \mathbf{size}
                                                   C.insert(i)
 insert(int x)
                                            return C
     if 1 \le x \le dim then
        if not V/x then
                                         Set difference (Set A, Set B)
           size += 1
                                            Set C = Set(A.dim)
           V[x] = true
                                            for i = 1 to A.dim do
                                                if A.contains(i) and not
 remove(int x)
                                                 B.contains(i) then
     if 1 \le x \le dim then
                                                   C.insert(i)
                                   60
        if V/x then
                                            return C
           size == 1
           V[x] = \mathbf{false}
```

Caratteristiche

Gli insiemi possono essere memorizzati come un vettore di m elementi, se si vogliono salvare gli interi da 1 a m. Questo tipo di implementazione è molto semplice ed è efficiente verificare se un elemento appartiene ad un insieme. Come svantaggi presenta lo spreco di memoria, in quanto la memoria occupata è sempre O(m) indipendentemente dagli elementi salvati. E alcune operazioni sono inefficienti in O(m).

7.1.2 Insiemi realizzati con liste

Liste non ordinate

Operazioni di ricerca, inserimento e cancellazione O(n), operazioni di inserimento assumendo assenza O(1). Operazioni di unione intersezione, differenza O(nm).

Liste ordinate

Ricerca O(n) per liste e $O(\log n)$ per i vettori, inserimento e cancellazione O(n), unione, intersezione e differenza O(n).

7.1.3 Strutture dati complesse

Alberi bilanciati

Si ottengono insiemi con ordinamento, con ricerca, inserimento, cancellazione $O(\log n)$, iterazione O(n).

Tabelle hash

Si ottengono insiemi senza ordinamento, con ricerca, inserimento, cancellazione O(1), iterazione O(m).

7.2 Bloom filters

I bloom filters sono una via di mezzo tra gli insiemi realizzati con i vettori booleani e le tabelle hash, sono una struttura dati dinamica con bassa occupazione di memoria che non offre la possibilità di cancellazioni, nessuna memorizzazione e dà risposte probabilistiche.

7.2.1 Specifica

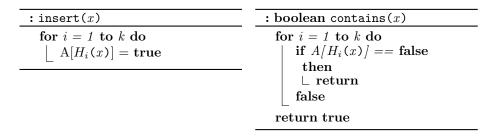
L'operazione di insert(x) inserisce l'elemento x nel bloom filter. **booleans** contains(x) se restituisce **false** l'elemento non sicuramente è presente, ma è possibile che ci siano dei falsi positivi. Si deve fare un trade-off tra occupazione di memoria e probabilità di un falso positivo. Indicata con ε la probabilità di un falso positivo, i bloom filters richiedono $1.44 \log_2(\frac{1}{\varepsilon})$ bit per elemento inserito.

7.2.2 Applicazioni

In chrome vengono utilizzati per indicare i siti con possibile malware, o in generale vengono utilizzati quando una verifica locale permette di evitare operazioni di I/O più costose. I falsi positivi inoltre possono essere utilizzati per mascherare un messaggio e garantire così un certo livello di privacy.

7.2.3 Implementazione

Vengono implementati attraverso un vettore booleando A di m bit inizializzato a **false** e k funzioni di hash $H_1, \ldots, H_k : U \to [0, \ldots, m-1]$.



7.2.4 Caratterizzazione matematica

Dati n oggetti, m bit e k funzioni hash, la probabilità di un falso positivo è:

$$\varepsilon = (1 - e^{-k\frac{n}{m}})^k$$

Dati n oggetti e m bit il valore ottimale per k è:

$$k = \frac{m}{n} \ln 2$$

Dati n oggetti e una probabilità di falsi positivi ε il numero di bit m richiesti è pari a:

$$m = \frac{n \ln \varepsilon}{(\ln 2)^2}$$

Capitolo 8

Grafi

8.0.1 Definizioni

Grafo orientato Si dice grafo orientato la coppia G = (V, E), dove V è l'insieme di nodi o vertici ed E è l'insieme di coppie ordinate (u, v) di nodi dette anche archi.

Grafo non orientato Si dice grafo non orientato la coppia G = (V, E), dove V è l'insieme di nodi o vertici ed E è l'insieme di coppie non ordinate (u, v) di nodi dette anche archi.

- Un vertice v è detto adiacente a u se esiste un arco (v, u).
- Un arco (v, u) è detto incidente a $v \in u$.
- In un grafo non orientato la relazione di adiacenza è simmetrica.
- n = |V| numero di nodi.
- m = |E| numero di archi.
- In un grafo non orientato $m \leq \frac{n(n-1)}{2} = O(n^2)$.
- In un grafo orientato $m \le n^2 n = O(n^2)$.
- La complessità di algoritmi sui grafi deve essere espressa sia un termini di n che di m.
- Un grafo con un arco tra tutte le coppie di nodi è detto completo.
- Un grafo si dice sparso se ha "pochi archi", ovvero con m = O(n) o $m = O(n \log n)$.
- Un grafo si dice dento se ha "molti archi", ovvero con $m = \Omega(n^2)$.
- Un albero libero è un grafo connesso con m = n 1.

- Un albero radicato è un albero libero sul quale è stata scelta una radice.
- Un insieme di alberi è un grafo detto foresta.
- Il grado di un nodo è il numero di archi incidenti su di esso.
- Nei grafi orientati si divide il grado in grado entrante per gli archi che incidono su di esso e in grado uscente per gli archi che incidono da esso.
- Si dice cammino C di lunghezza k in un grafo G = (V, E) una sequenza di nodi u_0, \ldots, u_k tali che $(u_i, u_{i+1}) \in E$ per $0 \le i \le k-1$.
- Si dice semplice un cammino i cui nodi sono tutti distinti.
- Si dice peso di un arco un valore associato all'arco dato da una funzione di peso $w: V \times V \to \mathbb{R}$.
- Un nodo v si dice raggiungibile da un nodo u se esiste almeno un cammino da u a v.
- Un grafo non orientato G = (V, E) è connesso se e solo se ogni suo nodo è raggiungibile da ogni altro nodo.
- G' è detto sottografo di G $G' \subseteq G$ se e solo se $V' \subseteq V$ e $E' \subseteq E$.
- G' è sottografo massimale di G se e solo se non esiste un altro sottografo G'' tale che G'' è connesso e più grande di G'.
- Un grafo G' = (V', E') è una componente connessa di G se e solo se è un sottografo connesso e massimale di G.
- In un grafo non orientato G = (V, E) un ciclo C di lunghezza k > 2 è una sequenza di nodi u_0, \ldots, u_k tale che $(u_i, i_{i+1}) \in E$ per ogni $0 \le i \le k-1$ e $u_0 = u_k$. Un ciclo è detto semplice se tutti i suoi nodi sono distinti.
- Un grafo è detto aciclico se non contiene cicli. Se orientato è detto DAG (directed acyclic graph).
- Dato un DAG, un suo ordinamento topologico è un ordinamento lineare dei suoi nodi tale che se $(u, v) \in E$, allora u appare prima di v nell'odinamento.
- Un grafo orientato G = (V, E) si dice fortemente connesso se e solo se ogni suo nodo è raggiungibile da ogni altro suo nodo.
- Un grafo G' = (V', E') è una componente fortemente connessa di G se e solo se è un sottografo connesso e massimale di G.

8.0.2 Specifica

In alcuni casi il grafo è dinamico ma sono possibili solo inserimenti e non è necessaria la parte di eliminazione (grafo caricato all'inizio).

: Graph

```
Graph() %Crea un nuovo grafo

Set V() %Restituisce l'insieme di tutti i nodi

int size() %Restituisce il numero di nodi

Set adj(Node u) %Restituisce i nodi adiacenti al nodo u

insertNode(Node u) %Inserisce il nodo u nel grafo

insertEdge(Node u, Node v) %Inserisce l'arco tra u e v nel grafo

deleteNode(Node u) %Elimina il nodo u dal grafo

deleteEdge(Node u, Node v) %Elimina l'arco tra i nodi u e v dal

grafo
```

8.1 Memorizzare grafi

8.1.1 Matrice di adiacenza

Le matrici di adiacenza sono ideali per i grafi densi. Un grafo orientato viene salvato in una matrice di dimensione $n \times n$ bit tale che:

$$m_{uv} = \begin{cases} 1 & (u, v) \in E \\ 0 & (u, v) \notin E \end{cases}$$

Per il grafo non orientato basta salvare la matrice sopra la diagonale principale esclusa in modo da occupare solamente $\frac{n(n-1)}{2}$ bit.

Grafi pesati Per i grafi pesati la matrice di booleani diventa una matrice di reali tale che:

$$m_{uv} = \begin{cases} peso & (u, v) \in E \\ +\infty & (u, v) \notin E \end{cases}$$

Analisi complessità

- Spazio richiesto $O(n^2)$.
- Verificare se u è adiacente a v richiede O(1).
- Iterare su tutti gli archi richiede $O(n^2)$

8.1.2 Liste di adiacenza

Le liste di adiacenza sono ideali per i grafi sparsi. Viene creato un vettore di dimensione n tale che in posizione u si trovi un insieme tale che contenga gli adiacenti. Occupa an + bm bit. Dove a è la dimensione del puntatore al nodo adiacente e b è la dimensione dell'adiacente. Per il grafo non orientato viene salvato anche l'arco inverso e occupa an + 2bm.

Grafi pesati Gli elementi della lista puntata sono coppie nodo di arrivopeso.

Analisi complessità

- Spazio richiesto O(n+m).
- Verificare se u è adiacente a v richiede O(n).
- Iterare su tutti gli archi richiede O(n+m)

8.1.3 Iterazioni su nodi e archi

```
: Iterazione su tutti i nodi del grafo

foreach u \in G.V() do

Esegui operazioni sul nodo

u

Esegui operazioni sul nodo

u;

foreach v \in G.adj(u) do

Esegui operazioni

sull'arco (u, v)
```

8.2 Visite dei grafi

Dato un grafo G=(V,E) e $r\in V$ radice o sorgente si intende per visita visitare una e una sola volta tutti i nodi che possono essere raggiunti da r.

```
 \begin{array}{l} \texttt{:} \ \texttt{graphTraversal}(\mathsf{Graph}\ G,\, \mathsf{Node}\ r) \\ \\ \texttt{Set}\ S = \mathsf{Set}()\ \% \mathsf{Insieme}\ \mathsf{generico} \\ \\ S.\mathsf{insert}(r)\ \% \mathsf{Da}\ \mathsf{specificare} \\ \{\mathsf{Marca}\ \mathsf{il}\ \mathsf{nodo}\ r\} \\ \\ \mathbf{while}\ S.\mathsf{size}() > \theta\ \mathbf{do} \\ \\ |\ \mathsf{Node}\ \mathsf{u} = \mathsf{S.remove}()\ \% \mathsf{Da}\ \mathsf{specificare} \\ \{\mathsf{Visita}\ \mathsf{il}\ \mathsf{nodo}\ \mathsf{u}\} \\ \\ \mathbf{foreach}\ v \in G.\mathsf{adj}(u)\ \mathbf{do} \\ \\ |\ \{\mathsf{Visita}\ \mathsf{l'arco}\ (\mathsf{u},\mathsf{v})\} \\ \\ \mathbf{if}\ v\ non\ \grave{e}\ \mathit{stato}\ \mathit{marcato}\ \mathbf{then} \\ \\ |\ \mathsf{Marca}\ \mathsf{il}\ \mathsf{nodo}\ \mathsf{v} \\ \\ \\ \mathsf{S.insert}(v)\ \% \mathsf{Da}\ \mathsf{specificare} \\ \end{aligned}
```

8.2.1 Visita in ampiezza o breadth-first search

In questo tipo di visita si visitano i nodi per livelli crescenti a partire dalla sorgente. Gli obiettivi di questa visita sono di visitare i nodi a distanza k prima dei nodi a distanza k+1, calcolare il cammino più breve da r a tutti gli altri nodi (distanze misurate come numero di archi attraversati). Generare un albero breadth-first contenente tutti i nodi raggiungibili da r tale per cui il cammino dalla radice r al nodo u nell'albero corrisponde al cammino più breve nel grafo.

Calcolo dei cammini più brevi o del numero di Erdös

L'algoritmo di erdos oltre a determinare la lunghezza del cammino più breve genera l'arco di copertura bfs che contiene tali cammini.

```
 \begin{array}{c} : \operatorname{erdos}(\operatorname{Graph}\ G,\,\operatorname{Node}\ r,\,\operatorname{int}\ []\ \operatorname{erdos},\,\operatorname{Node}\ []\ \operatorname{parents}) \\ \\ \operatorname{Queue}\ Q = \operatorname{Queue}() \\ \operatorname{Q.enqueue}(r) \\ \operatorname{foreach}\ u \in G.\mathtt{V}() - \{r\}\operatorname{do} \\ \\ \lfloor \operatorname{erdos}[\mathtt{u}] = \infty \\ \\ \operatorname{erdos}[\mathtt{r}] = 0 \\ \operatorname{parents}[\mathtt{r}] = \operatorname{nil} \\ \operatorname{while}\ \operatorname{not}\ Q.\operatorname{empty}()\ \operatorname{do} \\ \\ \lceil \operatorname{Node}\ \mathtt{u} = \operatorname{Q.dequeue}() \\ \{\operatorname{Visita}\ \mathrm{il}\ \operatorname{nodo}\ \mathtt{u}\} \\ \operatorname{foreach}\ v \in G.\operatorname{adj}(u)\ \operatorname{do} \\ \\ \lceil \operatorname{if}\ \operatorname{erdos}[v] = \infty\ \operatorname{then} \\ \\ \lfloor \operatorname{erdos}[v] = \operatorname{erdos}[\mathtt{u}] + 1 \\ \\ \operatorname{parents}[v] = \mathtt{u} \\ \\ Q.\operatorname{enqueue}(v) \\ \end{array}
```

Complessità

La complessità di una bfs è O(m+n) in quanto ognuno degli n nodi viene salvato nella coda al più una volta. Ogni volta che un nodo viene estratto tutti i suoi archi vengono analizzati una sola volta. Il numero di archi analizzati è pertanto $m=\sum_{u\in V} out_d(u)$, dove $out_d(u)$ è l'out-degree del nodo u.

8.2.2 Visita in profondità o depth-first search

La visita in profondità è una visita ricorsiva: per ogni nodo adiacente si visita ricorsivamente tale nodo, visitando ricorsivamente i suoi adiacenti e così via. Questo tipo di ricerca è spesso una subroutine in altri problemi, visita tutto il grafo, nono solo i nodi raggiungibili dalla radice e genera pertanto una foresta formata da una collezione di alberi depth-first. Si realizza attraverso uno stack che viene reso implicito attraverso la ricorsione.

Implementazione ricorsiva

Implementazione iterativa

Una dfs ricorsiva in casi di grafi molto profondi può superare la dimensione dello stack del linguaggio, si rende pertanto esplicito lo stack utilizzando una versione iterativa. Un nodo può essere inserito nella pila più volte in quanto il controllo viene fatto all'estrazione. Ha complessità O(m+n) con O(m) visite degli archi, O(m) estrazioni e inserimenti e O(n) visite dei nodi. Per la visita in post order quando un nodo viene scoperto viene inserito nello stack con il tag discovery, quando viene estratto un nodo con il tag discovery viene re-inserito con il tag finish e vengono inseriti tutti i suoi vicini. Quando viene estratto un nodo con il tag finish viene fatta la post-visita.

Componenti connesse

Ci si pone il problema di verificare se il grafo è connesso e se non lo è di identificare le sue componenti connesse. Un grafo risulta connesso se al termine della dfs tutti i suoi nodi sono marcati, altrimenti la visita deve ricominciare da capo da un nodo non marcato identificando una nuova componente del grafo. L'appartenenza ad una componente connessa viene identificata attraverso un vettore $id[\bar{l}]$ tale per cui id[u] è l'identificatore della componente connessa di appartenenza.

```
: int [] ccdfs(Graph G, int counter, Node u, int [] id)

id[u] = counter foreach v \in G.adj(u) do

if id[v] = 0 then

ccdfs(G, counter, v,

id)
```

Grafo non orientato aciclico

```
 \begin{array}{l} \textbf{boolean} \ [] \ \mathsf{hasCycle}(\mathsf{Graph}\ G) \\ \\ \textbf{boolean} \ [] \ \mathsf{visited} = \mathbf{new} \ \mathbf{boolean} \ [\mathsf{G.size}()] \\ \textbf{foreach} \ u \in G.\mathtt{V}() \ \mathbf{do} \\ & \big\lfloor \ \mathsf{visited}[\mathsf{u}] = \mathbf{false} \\ \\ \textbf{foreach} \ u \in G.\mathtt{V}() \ \mathbf{do} \\ & \big\lfloor \ \mathsf{if} \ \mathsf{not} \ \mathit{visited}[\mathsf{u}] \ \mathsf{then} \\ & \big\lfloor \ \mathsf{if} \ \mathsf{hasCycleRec}(G, \ u, \ \mathsf{nil}, \ \mathit{visited}) \ \mathsf{then} \\ & \big\lfloor \ \mathsf{return} \ \mathsf{true} \\ \\ \\ \textbf{return false} \\ \end{array}
```

Grafo orientato aciclico

Classificazione degli archi Ogni qual volta si esamina un arco da un nodo marcato ad un nodo non marcato tale arco diventa un arco dell'albero di copertura dfs T. Gli archi non inclusi nell'albero possono essere divisi in tre categorie:

- Se u è un antenato di v in T (u, v) è detto arco in avanti.
- Se u è un discendente di v in T (u, v) è detto arco all'indietro.
- Se i primi due non sussistono viene detto arco di attraversamento.

Indicato con time un contatore, il vettore dt il discovery time, o tempo di scoperta di un nodo e ft il finish time o tempo di fine di un nodo.

```
: dfs-schema(Graph G, Node u, int & time, int [] dt, int [] ft)
 {Visita il nodo u in pre-order}
 time += 1
 dt[u] = time
 foreach v \in G.adj(u) do
     {Visita l'arco (u, v) qualsiasi}
     if dt/v/=0 then
         {Visita l'arco (u, v) albero}
        dfs-schema(G, v, time, dt, ft)
     else if dt/u/ > dt/v/ and ft/v/ = 0 then
        Visita l'arco (u, v) indietro
     else if dt/u/ < dt/v/ and ft/v/ \neq 0 then
        Visita l'arco (u, v) avanti
     else
        Visita l'arco (u, v) attraversamento
  {Visita il nodo u in post-order}
 time +=1
 ft[u] = time
```

Classificare gli archi permette di dimostrare proprietà rispetto a questa classificazione e pertanto costruire degli algoritmi migliori. In particolare data una visita dfs di un grafo G per ogni coppia di nodi $u,v\in V$ solo una delle seguenti condizioni è vera:

- Gli intervalli [dt[u], ft[u]] e [dt[v], ft[v]] sono non-sovrapposti: allora u e v non sono discendenti l'uno dell'altro nella foresta DF.
- L'intervallo [dt[u], ft[u]] è contenuto in [dt[v], ft[v]], allora u è un discendente di v nella foresta DF.
- L'intervallo [dt[v], ft[v]] è contenuto in [dt[u], ft[u]], allora v è un discendente di u nella foresta DF.

Teorema un grafo è aciclico se e solo se non esistono archi all'indietro nel grafo.

Dimostrazione Se esiste un ciclo, sia u il primo nodo del ciclo che viene visitato e (v, u un arco del ciclo. Il cammino che connette v a u verrà prima o poi visitato e da v verrà scoperto l'arco all'indietro (v, u). Se esiste un arco all'indietro (u, v), dove v è un antenato di u allora esiste un cammino da v a u e un arco da u a v, ovvero un ciclo.

```
: hasCycle(Graph G, Node u, int & time, int [] dt, int [] ft)

time +=1

dt[u] = time

foreach v \in G.adj(u) do

if dt[v] == 0 then

if hasCycle(G, v, time, dt, ft) then

class if dt[u] > dt[v] and ft[v] == 0 then

return true

time +=1

ft[u] = time

return false
```

Ordinamento topologico

L'algoritmo per un ordinamento topologico consiste in una dfs in cui l'operazione di visita consiste nell'aggiungere il nodo in testa ad una lista a tempo di fine (ovvero post-ordine). L'output sarà pertanto una sequenza di nodi ordinata per tempo decrescente di fine. In questo modo quando un nodo è finito tutti i suoi discendenti sono stati aggiunti alla lista e aggiungendolo in testa è nell'ordine corretto.

```
: Stack ts-dfs(Graph G, Node u, boolean [] visited, Stack S)

visited[u] = true

foreach v ∈ G.adj(u) do

if not visited[v] then

ts-dfs(G, v, visited, S)

S.push(u)
```

Algoritmo di Kosaraju

Utilizzato per trovare le componenti fortemente connesse di un grafo orientato. Per farlo effettua una visita dfs al grafo, calcola il grafo trasposto G_t ed esegue una visita dfs sul grafo G_t utilizzando cc esaminando i nodi in ordine inverso di tempo di fine della prima visita. Le componenti connesse e i relativi alberi DF rappresentano le componenti fortemente connesse di G. (Sostituito dall'algoritmo di Tarjan che richiede una sola visita). Applicando l'algoritmo topologico si

```
\begin{array}{l} \hbox{:} \ \hbox{int} \ [] \ \mathtt{scc}(\mathsf{Graph} \ G) \\ \\ \hbox{Stack} \ S = \ \mathtt{topSort}(G) \ \% \mathtt{First} \ \mathtt{visit} \\ \\ \hbox{Graph} \ G^T = \ \mathtt{transpose}(G) \ \% \mathtt{Graph} \ \mathtt{transposal} \\ \\ \hbox{\textbf{return}} \ \mathtt{cc} G^T, \ S \ \% \mathtt{Second} \ \mathtt{visit} \end{array}
```

è sicuri che se un arco (u, v) non appartiene ad un ciclo, u viene listato prima di v nella sequenza ordinata e gli archi di un ciclo vengono listati in un qualche ordine che è ininfluente. Si utilizza topSort() per ottenere i nodi in ordine decrescente di tempo di fine. Essendo che ogni passo di questo algoritmo richiede O(n+m), la complessità totale è O(m+n).

Calcolo del grafo trasposto Dato un grafo orientato G = (V, E) il corrispettivo grafo trasposto $G_t = (V, E_t)$ è un grafo con gli stessi nodi ma con gli archi orientati nel senso opposto: $E_t = \{(u, v) | (v, u) \in E\}$. L'algoritmo per il suo calcolo ha costo O(m + n).

```
\begin{array}{l} \textbf{:} \ \textbf{int} \ \big[ \ \textbf{transpose}(\mathsf{Graph} \ G) \\ \\ \textbf{Graph} \ G^T = \mathtt{Graph}(G) \\ \textbf{foreach} \ u \in G.\mathtt{V()} \ \textbf{do} \\ \\ \big\lfloor \ G^T.\mathtt{insertNode}(u) \\ \textbf{foreach} \ u \in G.\mathtt{V()} \ \textbf{do} \\ \\ \big\lfloor \ G^T.\mathtt{insertEdge}(v, u) \\ \\ \textbf{return} \ G^T \end{array}
```

Calcolo delle componenti connesse Invece di esaminare i nodi in ordine arbitrario questa versione li esamina nell'ordine LIFO memorizzato nello stack.

```
: ccdfs(Graph G, int counter,
: int [] cc(Graph G, Stack S)
                                        Node u, int //id)
 int [] id = new int [G.size()]
                                          id[u] = counter
 foreach u \in G.V() do
  |\operatorname{id}[u]| = 0
                                          foreach v \in G.adj(u) do
                                             if id/u/==0 then
 int counter = 0
                                                 ccdfs(G, counter, v,
 while not S.empty() do
     u = S.pop()
     if id/u/==0 then
        counter +=1
        ccdfs(G, counter, u,
          id)
 return id
```

Dimostrazione di correttezza Si costruisca il grafo delle componenti $C(G) = (V_C, E_C)$, dove $V_C = \{C_1, \dots, C_k\}$, dove C_i è la i-esima SCC di G e $E_C = \{(C_i, C_j) | \exists (u_i, u_j) \in E : u_i \in C_i \land u) j \in C_j\}$. Il grafo delle componenti è aciclico e inoltre $C(G^T) = [C(G)]^T$. I discovery e finish time del grafo delle componenti corrispondono ai corrispettivi del primo nodo visitato in C: $dt(C) = \min\{dt(u) | u \in C\}$ e $ft(C) = \max\{ft(u) | u \in C\}$.

Teorema Siano C e C' due distinte SCCs nel grafo orientato G=(V,E). Se c'è un arco $(C,C')\in E_C$, allora ft(C)>ft(C').

Corollario Siano C_u e C_v due SCCs distinte nel grafo orientato G=(V,E), se cè un arco $(u,v)\in E_T$ tale che $u\in C_u$ e $v\in C_v$, allora $ft(C_u)<$

 $ft(C_v)$.

$$(u,v) \in E_T \Rightarrow$$

$$(v,u) \in E \Rightarrow$$

$$(C_v, C_u) \in E_C \Rightarrow$$

$$ft(C_v) > ft(C_u) \Rightarrow$$

$$ft(C_u) < ft(C_v)$$

Conclusione Se le componenti C_u e C_v sono connesse da un arco $(u,v) \in E_T$ allora dal corollario $ft(C_u) < ft(C_v)$ e dall'algoritmo la visita di C_v inizierà prima della visita di C_u . Non esistono cammini tra C_u e C_v in E_T altrimenti il grafo sarebbe ciclico, pertando dall'algoritmo la visita di C_v non raggiungerà mai C_u , pertanto cc() assegnerà correttamente gli identificatori delle componenti ai nodi.

Capitolo 9

Strutture dati speciali

9.1 Code con priorità

Una coda con priorità è una struttura dati astratta simile ad una coda in cui ogni elemnto inserito possiede una priorità. Si dividono in min-priority queue in cui l'estrazione avviene per valore crescente di priorità e max-priority queue, in cui l'estrazione avviene per valore decrescente di priorità. Le operazioni permesse sono di inserimento in coda, estrazione dell'elemento con priorità di valore min/max e di modifica di priorità di un elemento inserito.

9.1.1 Specifica

: MinPriorityQueue

%Crea una coda con priorità vuota

MinPriorityQueue()

%Restituisce true se la coda con priorità è vuota

boolean isEmpty()

 $\% {\tt Restituisce}$ l'elemento minimo di una coda con priorità non vuota

ltem min()

% Rimuovee restituisce l'elemento minimo di una coda con priorità non vuota

Item DeleteMin()

%Inerisce l'elemento x con priorità p all'interno della coda con priorità, restituendo un oggetto PriorityItem che identifica x all'interno della coda

PriorityItem insert(Item x, int p)

%Diminuisce la priorità dell'oggetto identificato da y portandola a p decrease(PriorityItem x, int p)

9.1.2 Implementazioni

Metodo	Lista o vettore	Lista	Vettore	Albero
	non ordinato	ordinata	ordinato	RB
min()	O(n)	O(1)	O(1)	$O(\log n)$
deleteMin()	O(n)	O(1)	O(n)	$O(\log n)$
insert()	O(n)	O(n)	O(n)	$O(\log n)$
decrease()	O(n)	O(n)	$O(\log n)$	$O(\log n)$

L'implementazione più comune è attraverso gli heap, strutture speciali che associano i vantaggi di un albero (esecuzioni in tempo $O(\log n)$) e vantaggi di un vettore (memorizzazione efficiente).

9.1.3 Heap

Definizioni di alberi

Albero binario perfetto In un albero binario perfetto tutte le foglie hanno la stessa altezza h, tutti i nodi interni hanno grado 2 e dato n il numero di nodi ha altezza $h = \lfloor \log n \rfloor$. Data l'altezza h ha numero di nodi $n = 2^{h+1} - 1$.

Albero binario completo In un albero binario completo tutte le foglie hanno altezza h o h-1, tutti i nodi a livello h sono accatastati a sinistra e tutti i nodi hanno grado 2 tranne al più uno. Dato il numero di nodi n ha altezza $h = |\log n|$.

Alberi binari heap

Un albero binario max-heap (min-heap) è un albero completo tale che il valore memorizzato nel nodo è maggiore (minore) dei valori memorizzati nei suoi figli. Un albero heap non impone una relazione di ordinamento totale tra i figli di un nodo, pertanto è un ordinamento parziale.

Memorizzazione

Gli alberi binari heap sono memorizzati tramite un vettore heap $A=[0,\ldots,n-1]$ tale per cui:

- La radice si trova all'indice i = 0, ovvero root()=0.
- Il padre del nodo salvato all'indice i si trova in $p(i) = \lfloor \frac{(i-1)}{2} \rfloor$.
- Il figlio sinistro del nodo salvato all'indice i si trova in l(i) = 2i + 1.
- Il figlio destro del nodo salvato all'indice i si trova in r(i) = 2i + 2.

Proprietà max-heap sul vettore: $A[i] \ge A[l(i)], [i] \ge A[r(i)]$. Proprietà min-heap sul vettore: $A[i] \le A[l(i)], [i] \le A[r(i)]$.

heapsort()

L'heapsort() ordina un max-heap "in-place" prima costruendo un max-heap nel vettore e poi spostando l'elemento max in ultima posizione, ripristinando la proprietà max-heap. Utilizza pertanto le funzioni heapBuild() che costruisce un max-heap a partire dal vettore non ordinato e maxHeapRestore() che ripristina le proprietà max-heap.

maxHeapRestore() Riceve come input un vettore A e un indice i, tale per cui gli alberi binari con radici l(i) e r(i) sono max-heap e il suo obiettivo è modificare "in-place" il vettore A in modo tale che l'albero binario con radice i sia un max-heap. Essendo che ad ogni chiamata vengono eseguiti O(1) confronti, e se il nodo i non è massimo si chiama ricorsivamente sui figli e che l'esecuzione termina quando si raggiunge una foglia e l'altezza dell'albero è pari a $\lfloor \log n \rfloor$ $T(n) = O(\log n)$.

Dimostrazione della correttezza per induzione sull'altezza Al termine dell'esecuzione l'albero radicato in A[i] rispetta la proprietà max-heap.

- Caso base h=0: se l'altezza è zero esiste un unico nodo che rispetta la proprietà.
- Ipotesi induttiva: l'algoritmo funziona correttamente su tutti gli alberi di altezza inferiore ad h.
- Passo induttivo:
 - Caso 1: $A[i] \ge A[l(i)], A[i] \ge A[r(i)]$, allora l'albero radicato in A[i] rispetta la proprietà di max-heap e l'esecuzione termina.
 - Caso 2: A[l(i)] > A[i], A[r(i)] > A[i], viene fatto uno scambio $A[i] \leftrightarrow A[l(i)]$, dopo lo scambio $A[i] \ge A[l(i)], A[i] \ge A[r(i)]$, il sottoalbero radicato in r(i) rimasto inalterato, mentre il sottoalbero radicato in l(i) può aver perso la proprietà, pertanto si svolge la chiamata ricorsiva su di esso che ha altezza minore di h, pertanto è corretto.
 - Caso 3: simmetrico rispetto al caso 2.

heapBuild() Sia A[1,...,n] un vettore da ordinare, tutti i nodi $A[\lfloor \frac{n}{2} \rfloor + 1,...,n]$ sono foglie dell'albero e pertanto heap contenenti un elemento. La procedura heapBuild() attraversa i restanti nodi dell'albero a partire da $\lfloor \frac{n}{2} \rfloor$ fino ad 1 ed esegue maxHeapRestore() su ognuno di essi. L'algoritmo ha complessità $\Theta(\log n)$. Aggiungere dimostrazione, non la capisco.

```
: heapBuild(Item [] A, int n)

for i = \lfloor \frac{n}{2} \rfloor down to 1 do

\lfloor \max HeapRestore(A, i, n)
```

Correttezza Si dimostra attraverso l'invariante di ciclo: all'inizio di ogni iterazione del ciclo **for** i nodi $[i+1,\ldots,n]$ sono radice di uno heap.

- Inizializzazione: all'inizio $i = \lfloor \frac{n}{2} \rfloor$. Si supponga che $\lfloor \frac{n}{2} \rfloor + 1$ non sia una foglia, pertanto esiste almeno il figlio sinistro $2\lfloor \frac{n}{2} \rfloor + 2$, con indice superiore ad n, pertanto assurdo. La dimostrazione vale per tutti gli indici successivi.
- Conservazione: È possibile applicare maxHeapRestore() al nodo i in quanto $2i \le 2i+1 \le n$ sono entrambi radici di heap. Al termine dell'iterazione tutti i nodi $[1, \ldots, n]$ sono radici di heap.
- Conclusione: al termine i = 0, pertanto il nodo 1 è radice di uno heap.

Implementazione heapsort Il primo elemento contiene il massimo, viene collocato in fondo, l'elemento in fondo viene collocato in testa, si chiama max-HeapRestore() per ripristinare la situazione e la dimensione dello heap viene progressivamente ridotta. L'algoritmo ha complessità $\Theta(n \log n)$ in quanto heapBuild() ha costo $\Theta(n)$ e la chiamata di maxHeapRestore() costa $\Theta(\log i)$ in un heap con i elementi. Pertanto $T(n) = \sum_{i=2}^n \log i + \Theta(n) = \Theta(n \log n)$.

```
: heapsort(ltem [] A, int n)

heapBuild(A, n)

for i = n down to 2 do

A[1] \leftrightarrow A[i]

maxHeapRestore(A, 1, i-1)
```

Correttezza Si dimostra la correttezza per invariante di ciclo. Al passo i il sottovettore $A[i+1,\ldots,n]$ è ordinato, $A[1,\ldots,i] \leq A[i+1,\ldots,n]$ e A[1] è la radice di un vettore heap di dimensione i. COMPLETARE DIMOSTRAZIONE

9.1.4 Implementazione di code con priorità

Si vedrà l'implementazione di una min-priority queue, visto che la max-priority è speculare.

Memorizzazione

```
: PriorityItem

int priority
Item value
int pos;
```

```
: swap(PriorityItem [] H, int i, int j)

H[i] \leftrightarrow H[j]
H[i].pos = i
H[j].pos = j
```

Inizializzazione

```
: PriorityQueue
int capacity
int dim
PriorityItem [] H
PriorityQueuePriorityQueue(int n)

    PriorityQueue t = new PriorityQueue
    t.capacity = n
    t.dim = 0
    t.H = new PriorityItem [1,...,n]
    return t
```

Inserimento

minHeapRestore()

Cancellazione e lettura minimo

```
: Item DeleteMin()

precondition: dim > 0
swap(H, 1, dim)
dim -= 1
minHeapRestore(H, 1, dim)
return H[dim+1].value

: Item min()
precondition: dim > 0
return H[1].value
```

Decremento priorità

Complessità

Tutte le operazioni che modificano gli heap devono sistemare la proprietà heap lungo un cammino radice-foglia (deleteMin()) oppure lungo un cammino nodoradice (insert(), decrease()). Essendo l'altezza $\lfloor \log n \rfloor$ il costo di tali operazioni è $O(\log n)$.

Operazione	Costo
insert()	$O(\log n)$
deleteMin()	$O(\log n)$
min()	$\Theta(1)$
decrase()	$O(\log n)$

9.2 Insiemi disgiunti - Merge-find set

In alcune applicazioni si è interessati a gestire una collezione $S = \{S_1, \dots, S_k\}$ di insiemi dinamici disgiunti tali che:

- $\forall i, j : i \neq j \Rightarrow S_i \cap S_j = \emptyset$.
- $\bullet \bigcup_{i=1}^k S_i = S.$

Un esempio di questi insiemi sono le componenti di un grafo. Le operazioni fondamentali sono:

- \bullet Creare n insiemi disgiunti, ognuno composto da un unico elemento.
- merge(): unire più insiemi.
- \bullet find(): identificare l'insieme a cui appartiene un elemento.

Rappresentante

Ogni insieme è identificato da un rappresentante univoco, un qualunque membro dell'insieme. Le operazioni di ricerca del rappresentante su uno stesso insieme devono restituire sempre lo stesso oggetto. Il rappresentante può cambiare solo in caso di unione.

9.2.1 Specifica

```
: Mfset
  %Crea n componenti {1},...,{n}
  Mfset Mfset(int n)
  %Restituisce il rappresentante della componente x
  int find(int x)
  %Unisce le componenti che contengono x e y
  merge(int x, int y)
```

9.2.2 Componenti connesse dinamiche

Per trovare le componenti connesse di un grafo non orientato dinamico si inizia con componenti connesse costituite da un unico vertice, per ogni $(u,v) \in E$ si esegue merge(u,v) e alla fine ogni insieme disgiunto rappresenta una componente connessa.

```
: Mfset cc(Graph \ G)

Mfset M = Mfset(G.n)

foreach u \in G.V() do

foreach v \in G.adj(u) do

M.merge(u, v)

return M
```

Questo algoritmo ha complessità O(n) + m operazioni merge(), interessante per la capacità di gestire grafi dinamici.

Capitolo 10

Programmazione dinamica

Si dice programmazione dinamica un metodo per dividere un problema ricorsivamente in sottoproblemi in modo che ogni sottoproblema venga rivolto una volta sola e la sua soluzione venga memorizzata in una tabella. Se un sottoproblema deve essere risolto nuovamente si ottiene la sua soluzione dalla tabella (lookup in O(1)).

10.1 Approccio generale

Se si parte da un problema di ottimizzazione si definisce la soluzione in maniera ricorsiva, successivamente si definisce il valore della soluzione in maniera ricorsiva (primo passo per problemi di conteggio). Se da qui non sono presenti sottoproblemi ripetuti si utilizza divide et impera; se sono presenti sottoproblemi ripetuti e bisogna risolverli tutti si utilizza la programmazione dinamica, se non devono essere risolti tutti si usa memoization. Dalla tabella delle soluzioni si ottiene l'output numerico o la ricostruzione della soluzione che permette di arrivare alla soluzione ottima.

10.1.1 Evitare di risolvere i problemi più di una volta

Quando si risolve un problema si memorizza il risultato ottenuto in una tabella DP, che può essere un vettore, una matrice o un dizionario. La tabella deve contenere un elemento per ogni sottoproblema che deve essere risolto.

- Casi base: si memorizzano i casi base direttamente nella tabella.
- Iterazione bottom-up: si parte dai sottoproblemi che possono essere risolti direttamente a partire dai casi base, si sale verso problemi sempre più grandi fino a raggiungere il problema originale.

10.1.2 Ricostruire la soluzione

Per ricostruire la soluzione si parte dalla definizione ricorsiva del problema, la dimensione di n indica l'indice sulla tabella che si deve controllare e si definisce un controllo su quale delle chiamate ricorsive viene realmente effettuata.

10.2 Memoization

Questa tecnica fonde l'approccio di memorizzazione della programmazione dinamica con quello top-down di divide-et-impera: si crea una tabella DP inizializzata con un valore speciale ad indicare che un certo sottoproblema non è ancora stato risolto. Ogni volta che si deve risolvere un sottoproblema si controlla nella tabella se è già stato risolto precedentemente:

- già risolto: si utilizza il risultato della tabella.
- non risolto: si calcola il risultato e lo si memorizza

In questo modo ogni sottoproblema viene calcolato una sola volta e memorizzato come nella versione bottom-up. Questa tecnica presenta vantaggi quando invece di utilizzare una tabella si utilizza un dizionario in quanto non è più necessario fare inizializzazione.

Implementazione C++ 10.1: Memoization automatica in Python

```
1
   from functools import wraps
2
3
   def memo(func):
4
        cache = \{\}
5
        @wraps(func)
6
        def wrap(*args):
7
            if args not in cache:
8
                 cache[args] = func(*args)
9
            return cache [args]
10
        return wrap
```